



机器学习与数据挖掘


模型非线性化、过拟合与正则化

课程大纲


- 模型非线性化
- 过拟合
- 模型选择
- 正则化

引言

- 线性回归只能对输入 x 和输出 y 之间的线性关系进行建模




- 对于线性分类器，其决策边界只能是线性的




- 对于更复杂的任务，模型应该具备更多的能力以捕获：

- 非线性输入-输出关系




- 非线性决策边界





线性模型过于简单.....我们需要更复杂的模型


线性模型有严重的局限性：更灵活的模型！——bias(偏差)



红色的折线 = 常数 + 一组  的和




所有分段线性曲线 = 常数 + 一组  的和



曲线更多段就需要更多的 

超越分段线性?



基本想法：
用分段线性曲线近似连续曲线

——为了得到好的近似，我们需要足够的分段


如何构建具备非线性建模能力的模型？

基本思想：使用基函数将线性模型非线性化

$$[x] \rightarrow [x, x^2, x^3]$$


红色的折线 = 常数 + 一组  的和




如何表示这个函数？



sigmoid函数

$$y = \frac{1}{1 + e^{-(b + wx_1)}}$$
$$= \text{sigmoid}(b + wx_1)$$





通过基函数进行非线性化


- 通过多项式变换特征:

$$[x] \rightarrow [x, x^2, x^3]$$

单个特征被扩展为 3 个特征


- 使用原始特征的模型

$$\begin{aligned} f(x) &= w_0 + w_1 x \\ &= [1, x] \mathbf{w} \end{aligned}$$



- 使用扩展特征的模型

$$\begin{aligned} f(x) &= w_0 + w_1 x + w_2 x^2 + w_3 x^3 \\ &= \phi(x) \mathbf{w} \end{aligned}$$



- 通常，这种变换可以表示为：

$$[x_1, x_2, \dots, x_m] \rightarrow [\phi_1(\mathbf{x}), \phi_2(\mathbf{x}), \dots, \phi_n(\mathbf{x})] \triangleq \boldsymbol{\phi}(\mathbf{x})$$

基函数

$\phi_k(\mathbf{x})$ 可以是任何能够产生有意义特征的函数，例如：

$$\sqrt{x}, \quad \log x, \quad \frac{1}{x}, \quad x_1 + x_2, \quad x_1 - x_2, \quad x_1 x_2$$

- 非线性化后的模型现在变为：

$$f(\mathbf{x}) = \phi(\mathbf{x})\mathbf{w}$$

这被称为基函数模型

基函数模型关于 $\mathbf{x}$ 是非线性的，但关于模型参数 $\mathbf{w}$ 仍然是线性的

- 使用非线性变换后的特征 $\boldsymbol{\phi}(\mathbf{x})$ ，回归问题的最优模型参数 $\mathbf{w}^*$ 通过优化损失函数获得：

$$L(\mathbf{w}) = \frac{1}{N} \|\boldsymbol{\Phi}(\mathbf{X})\mathbf{w} - \mathbf{y}\|^2$$

$$\text{其中 } \boldsymbol{\Phi}(\mathbf{X}) \triangleq \begin{bmatrix} \boldsymbol{\phi}(\mathbf{x}^{(1)}) \\ \vdots \\ \boldsymbol{\phi}(\mathbf{x}^{(N)}) \end{bmatrix}$$

- 使用符号 $\Phi = \Phi(\mathbf{X})$ ，最优模型参数 $\mathbf{w}^*$ 为：

$$\mathbf{w}^* = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$

与线性回归相同，只是将 $\mathbf{X}$ 替换为 Φ

- 我们也可以使用数值方法（例如梯度下降）来获得最优解

- 对于使用基函数的分类问题，交叉熵损失变为：

$$L(\mathbf{W}) = -\frac{1}{N} \sum_{\ell=1}^N \sum_{k=1}^K y_k^{(\ell)} \log [\text{softmax}_k(\boldsymbol{\phi}(\mathbf{x}^{(\ell)})\mathbf{W})]$$

最优的 $\mathbf{W}^*$ 只能通过数值方法获得

- 将 $\boldsymbol{\phi}(\mathbf{x}^{(\ell)})$ 表示为 $\boldsymbol{\phi}^{(\ell)}$ ，可以推导出梯度等于

$$\frac{\partial L(\mathbf{W})}{\partial \mathbf{w}_j} = \frac{1}{N} \sum_{\ell=1}^N (\text{softmax}_j(\boldsymbol{\phi}^{(\ell)}\mathbf{W}) - y_j^{(\ell)}) \boldsymbol{\phi}^{(\ell)T}$$


与多类别逻辑回归相同，只是将 $\mathbf{x}^{(\ell)}$ 替换为 $\boldsymbol{\phi}^{(\ell)}$

课程大纲


- 模型非线性化
- 过拟合
- 模型选择
- 正则化

过拟合


- 高维特征 $\phi(\mathbf{x})$ 往往能更好地拟合训练数据



1阶



3阶





5阶

哪个模型更好??

- 从拟合训练数据的角度来看，模型阶数越高，拟合效果看起来肯定越好

- 但是高阶模型在测试数据上的表现可能很差



模型在新数据上表现良好的能力被称为**模型的泛化能力**

过拟合

训练数据上损失小，测试数据上损失大
为什么？


一个极端的例子：

Training data: $\{(\mathbf{x}^1, \hat{y}^1), (\mathbf{x}^2, \hat{y}^2), \dots, (\mathbf{x}^N, \hat{y}^N)\}$

$$f(\mathbf{x}) = \begin{cases} \hat{y}^i & \exists \mathbf{x}^i = \mathbf{x} \\ random & otherwise \end{cases} \quad \text{Less than useless ...}$$


此函数的训练损失为零，但测试损失较大

过拟 Overfitting



Basic Example (From Prof. 李志毅)

过拟 How to Solve Overfitting




数据增强




Basic Example (From Prof. 李志毅)


欠拟合



欠拟合




过拟合



好的拟合

拟合情况与模型复杂度



模型复杂度

- 每个模型都对应着一个复杂度
- 但很难给出一个精确的表达式来描述模型复杂度
- 一般来说，模型复杂度取决于参数的数量，参数越多，模型越复杂
- 为了让模型表现良好，我们应该平衡模型复杂度和表征能力

课程大纲




- 模型非线性化
- 过拟合
- 模型选择
- 正则化

模型选择

- **模型选择**：给定一组模型 $\{\mathcal{M}_1, \dots, \mathcal{M}_m\}$ ，选择 **在未见过的测试数据上表现最好** 的那个


候选模型可以是同一种类型，也可以是不同类型

不能基于模型在训练数据上的表现来选择模型



验证集

- 拿出训练数据的一部分（20% ~ 30%）作为验证集，剩下的作为训练数据




训练集和验证集都 **不能包含测试样本**

验证集不能太小。为什么？

- 在训练集上训练模型，同时在留出的验证集上评估模型
- 选择在验证集上表现最好的模型

- 训练集和验证集上的预测误差



- 如果随着模型复杂度的增加，验证误差减小，则表明模型欠拟合
- 否则，则意味着模型过拟合

留一验证

- 普通验证方法存在的问题

训练数据通常是稀缺的。如果留出很大一部分用于验证，就没有足够的数据样本用于训练

- 一个折中方案：留一法验证

对于数据集中的每个样本，执行以下步骤：

- 将该样本作为验证集，其余所有样本作为训练集，训练模型并评估其在验证集上的性能
- 重复上述步骤，直到每个样本都被用作一次验证集
- 由于几乎整个数据集都用于训练（除了一个样本），因此模型可以充分利用所有数据，这通常可以提供更稳定的性能估计，适用于小数据集。



交叉验证

- 普通验证方法存在的问题


训练数据通常是稀缺的。如果留出很大一部分用于验证，就没有足够的数据样本用于训练

- 一个常用方案：*K 折交叉验证*

- 将整个训练数据集平均划分成 K 个子集

- 在 $(K - 1)$ 个子集上进行训练，
在剩下的一个子集上进行评估

- 重复上述步骤 K 次，每次都使用不同的子集进行验证



信息准则

- Akaike 信息量准则 (AIC)

$$AIC = 2M - 2\log(\mathfrak{l})$$

- M 是参数数量
- $\mathfrak{l}$ 是对数似然

- 贝叶斯信息量准则 (BIC)

$$AIC = M\log N - 2\log(\mathfrak{l})$$

- N 是训练数据样本的数量

这些准则只能用于概率模型，因为它们需要用到对数似然 $\mathfrak{l}$

课程大纲

- 模型非线性化
- 过拟合
- 模型选择
- 正则化

- 除了拟合训练数据之外，对参数施加一些先验偏好，例如：


$$\tilde{L}(\mathbf{w}) = L(\mathbf{w}) + \lambda \|\mathbf{w}\|_2^2$$

- $L(\mathbf{w})$ 是原始的回归或分类损失
- $\|\mathbf{w}\|_2 = \left(\sum_{k=1}^K w_k^2\right)^{\frac{1}{2}}$ 是 L_2 范数
- λ 是用于控制 $\|\mathbf{w}\|^2$ 影响的超参数



L_2 正则化

- L_2 正则化的特性

- 倾向于将模型参数向零收缩——如果 w 小于1，那么 w^2 会更小
- λ 越大，对较小 w 值的偏好就越强
- 在实现上， L_2 正则化通常被称为权重衰减（Weight Decay），在框架如 PyTorch 中可以通过设置优化器的 “weight_decay” 参数轻松实现




受约束模型



---- 真实数据分布
(不可观测)

● 训练数据


● 测试数据




Basic Example (From Prof. 李志毅)

- 正则化影响的可视化


- 无正则化



1阶






3阶



5阶

- 采用 $\lambda = 1$ 的 L_2 正则化




- 另一种广泛使用的正则化是 L_1 正则化


$$\tilde{L}(\mathbf{w}) = L(\mathbf{w}) + \lambda \|\mathbf{w}\|_1$$

其中 $\|\mathbf{w}\|_1 \triangleq \sum_{k=1}^K |w_k|$ 是 L_1 范数

- L_2 范数和 L_1 范数的等高线



L_2 范数



L_1 范数

- 与 L_2 正则化类似， L_1 正则化也倾向于使模型参数具有较小的值
- 但是， L_1 正则化通常会**导致 w 出现稀疏解**，即 w 中的许多元素为零

