




机器学习与数据挖掘

视觉表示学习



什么是表示学习？

表示学习旨在将每个数据实例映射到 $\mathbb{R}^d$ 空间中紧凑的向量



关键在于如何得到这个映射!!!

表示学习的目标

尽可能多地保留原始数据的语义信息



0.6	0.3	0.1	...
-----	-----	-----	-----



0.8	0.5	0.3	...
-----	-----	-----	-----



0.4	0.2	0.9	...
-----	-----	-----	-----

表示学习的目标

尽可能多地保留原始数据的语义信息



0.6	0.3	0.1	...
-----	-----	-----	-----



0.8	0.5	0.3	...
-----	-----	-----	-----



0.4	0.2	0.9	...
-----	-----	-----	-----



推远





拉近

表示学习的目标

文本表示学习


将文本映射为向量，向量间的某种距离能够反映语义相似性




表示学习的目标

跨模态表示学习


学习共享的表示空间，对齐不同模态的语义信息



例子：用 $\mathbb{R}^2$ 中的向量表示手写数字，为了获得良好的表示，来自同一数字的图像的表达应该彼此接近。



2D latent space



Sampling snapshots

- 什么样的表示才算好？

好的表示应该尽可能保留原始数据的语义信息，而不是所有信息。

为什么需要表示学习？


- 与原始数据相比，表示对于下游应用更加友好，这是因为表示具有以下特点：
 - ✧ 丢弃无关信息，同时保留重要的语义信息
 - ✧ 更加紧凑
- 表示可以应用于各种下游应用，例如：
 - ✧ 分类
 - ✧ 聚类
 - ✧ 相似性搜索
 - ✧ 异常检测

大纲

- 基于迁移学习的方法
- 自编码器
- 对比学习
- ViT & MAE预训练


监督学习案例

- 给定一组**图像-标签对** $\{x_i, y_i\}_{i=1}^N$ ，我们在给定的图像-标签对上训练一个分类器



- 最后一个卷积层的特征图输出可以看作是输入图像的表达

为什么??




除了卷积特征图，全连接倒数第二层的输出有时也被用作表示

大纲

- 基于迁移学习的方法
- 自编码器
- 对比学习
- ViT & MAE预训练

无标签场景


- 当给定的数据集不包含标签时
 - 1) 在一个带有标签的**辅助数据集**（例如，ImageNet）上训练 CNN)
 - 2) 可以通过将新数据集的图像传递到预训练的 CNN 来获得图像的表达



预训练的 CNN 可以被看作是一个**特征提取器**


无标签场景&辅助数据集

- 在这种情况下，我们使用无监督学习
- 一个直接的方法是在给定的无标签数据 $\{x_i\}_{i=1}^N$ 上训练一个自编码器，然后使用编码器来提取表示



PCA 可以被看作是一个线性自编码器

- 我们也可以在无标签数据 $\{x_i\}_{i=1}^N$ 上训练**生成模型**，并使用生成模型来提取表示




使用生成方法，各种先验知识可以很容易地施加到学习过程中

大纲

- 基于迁移学习的方法
- 自编码器
- 对比学习
- ViT & MAE预训练

对比学习：SimCLR [Chen et al., 2020]

- 数据增强



➤ 通过应用上述一种或多种数据增强方法来扩增原始图像 $\mathbf{x}_i$ ，得到

$$\mathbf{x}_i^+ = \text{aug}(\mathbf{x}_i)$$

- SimCLR 的基本思想是拉近 $\mathbf{x}_i$ 和 $\mathbf{x}_i^+$ 的表示，同时将 $\mathbf{x}_i$ 的表示推离其他样本 $\mathbf{x}_j$ 和 $\mathbf{x}_j^+$ 的表示，其中 $j \neq i$





Figure 2. A simple framework for contrastive learning of visual representations. Two separate data augmentation operators are sampled from the same family of augmentations ($t \sim \mathcal{T}$ and $t' \sim \mathcal{T}$) and applied to each data example to obtain two correlated views. A base encoder network $f(\cdot)$ and a projection head $g(\cdot)$ are trained to maximize agreement using a contrastive loss. After training is completed, we throw away the projection head $g(\cdot)$ and use encoder $f(\cdot)$ and representation $\mathbf{h}$ for downstream tasks.



➤ 所有的 $\mathbf{z}_i$ 都来自同一个神经网络

$$\text{Loss} = -\log \frac{e^{\text{sim}(\mathbf{z}_i, \mathbf{z}_i^+)/\tau}}{e^{\text{sim}(\mathbf{z}_i, \mathbf{z}_i^+)/\tau} + \sum_{j \neq i} e^{\text{sim}(\mathbf{z}_i, \mathbf{z}_j)/\tau} + \sum_{j \neq i} e^{\text{sim}(\mathbf{z}_i, \mathbf{z}_j^+)/\tau}}$$


其中 $\mathbf{z} = g(f(\mathbf{x}))$, $\text{sim}(\mathbf{z}_i, \mathbf{z}_j) = \mathbf{z}_i^T \mathbf{z}_j / \|\mathbf{z}_i\| \|\mathbf{z}_j\|$

InfoNCE loss, 和互信息紧密相关

- 训练之后，编码器函数 $f(\cdot)$ 的输出可以被看作是输入图像 $\mathbf{x}$ 的表示

$$\mathbf{h} = f(\mathbf{x})$$


$g(\cdot)$ 被称为投影头，它通常由浅 MLP 实现



评估表示的质量

- 对学习到的特征进行线性探测
 - 在 ImageNet 的训练集上用 SimCLR 训练特征编码器
 - 冻结特征编码器，在输出特征之上训练线性分类器

Top-1 accuracy





- SimCLR 特征上的半监督学习
 - 在 ImageNet 的训练集上用 SimCLR 训练特征编码器
 - 在 ImageNet 上用 1% / 10% 的标记数据微调编码器

Method	Architecture	Label fraction	
		1%	10%
		Top 5	
Supervised baseline	ResNet-50	48.4	80.4
<i>Methods using other label-propagation:</i>			
Pseudo-label	ResNet-50	51.6	82.4
VAT+Entropy Min.	ResNet-50	47.0	83.4
UDA (w. RandAug)	ResNet-50	-	88.5
FixMatch (w. RandAug)	ResNet-50	-	89.1
S4L (Rot+VAT+En. M.)	ResNet-50 (4×)	-	91.2
<i>Methods using representation learning only:</i>			
InstDisc	ResNet-50	39.2	77.4
BigBiGAN	RevNet-50 (4×)	55.2	78.8
PIRL	ResNet-50	57.2	83.8
CPC v2	ResNet-161(*)	77.9	91.2
SimCLR (ours)	ResNet-50	75.5	87.8
SimCLR (ours)	ResNet-50 (2×)	83.0	91.2
SimCLR (ours)	ResNet-50 (4×)	85.8	92.6

Table 7. ImageNet accuracy of models trained with few labels.

SimCLR 设计选择

- 投影头




线性/非线性投影头大幅提高了表示质量。可能的原因是:

- 1) 空间 z 更像一个专门为 SimCLR 代理任务优化的空间
- 2) 通过利用投影头 $g(\cdot)$, 更多的信息可以保留在表示空间 h 中

- 使用大批量

- 大的训练批量大小对于SimCLR 至关重要
- 但是大的训练批量也会导致大的内存占用，从而对硬件提出更高的要求




与互信息的联系

- 对于服从联合分布 $p(x, y)$ 的两个随机变量 X 和 Y ，它们之间的互信息定义为

$$I(X; Y) \triangleq \int p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy \quad \longleftrightarrow \quad KL(p(x, y) \| p(x)p(y))$$

$$= \int p(x, y) \log \frac{p(y|x)}{p(y)} dx dy \quad \longleftrightarrow \quad H(Y) - H(Y|X)$$

$$= \int p(x, y) \log \frac{p(x|y)}{p(x)} dx dy \quad \longleftrightarrow \quad H(X) - H(X|Y)$$



- 互信息的下界被证明为

$$I(X; Y) \geq \log K + \mathbb{E}_{p(x,y) \prod_{k=1}^{K-1} p(y_k)} \left[\log \frac{e^{s(x,y)}}{e^{s(x,y)} + \sum_{k=1}^{K-1} e^{s(x,y_k)}} \right] \triangleq L$$

其中 $p(y) = \int p(x, y) dx$ 是 $p(x, y)$ 的边缘分布； $s(x, y)$ 可以是任何形式。

实践中， $s(x, y)$ 被训练以获得尽可能紧的下界

- 从 $p(x, y)$ 中抽取一个样本 (x, y) ，并从 $p(y)$ 中抽取 $K - 1$ 个独立样本 $\{y_k\}_{k=1}^{K-1}$ ，我们可以将下界估计为

$$L \approx \log K + \log \frac{e^{s(x,y)}}{e^{s(x,y)} + \sum_{k=1}^{K-1} e^{s(x,y_k)}}$$


Poole, Ben, Sherjil Ozair, Aaron Van Den Oord, Alex Alemi, and George Tucker. "On variational bounds of mutual information." In *International Conference on Machine Learning*, pp. 5171-5180, 2019.

Oord, Aaron van den, Yazhe Li, and Oriol Vinyals. "Representation learning with contrastive predictive coding." *arXiv preprint arXiv:1807.03748* (2018).

- 与 InfoNCE 损失的联系

➤ 定义两个随机变量 Z 和 Z^+ 如下

$$(z, z^+) = (g(f(\mathbb{T}(x))), g(f(\mathbb{T}(x))))$$



其中 $x \sim p(x)$ ，表示训练样本的分布；而 $\mathbb{T}(\cdot)$ 是随机增强算子

➤ 将样本 (z, z^+) 的分布表示为 $p(z, z^+)$

➤ 那么， Z 和 Z^+ 之间的互信息可以被限制为如下

$$I(Z; Z^+) \geq \log N + \log \frac{e^{\text{sim}(z, z^+)}}{e^{\text{sim}(z, z^+)} + \sum_{k=1}^{N-1} e^{\text{sim}(z, z_k^+)}}$$

其中 $(z, z^+) \sim p(z, z^+)$ ， $z_k^+ \sim p(z^+)$

- 边缘分布 $p(z)$ 和 $p(z^+)$ 是相同的，因此我们可以
 - 将 (z_i, z_i^+) 视为从联合分布 $p(z, z^+)$ 中抽取的样本
 - 将所有其他样本 $\{z_j, z_j^+\}_{j \neq i}$ 视为从 $p(z^+)$ 中独立抽取的样本

那么，下界可以写成如下形式

$$I(Z; Z^+) \geq \log(2N - 1) + \log \frac{e^{\text{sim}(z_i, z_i^+)}}{e^{\text{sim}(z_i, z_i^+)} + \sum_{j \neq i} e^{\text{sim}(z_i, z_j)} + \sum_{j \neq i} e^{\text{sim}(z_i, z_j^+)}}$$

它是 InfoNCE 损失的负数

因此，最小化 InfoNCE 损失可以理解为最大化 Z 和 Z^+ 之间的互信息


- 动量对比学习 [He et al., 2019]
 - 负样本的数量在对比学习中非常重要
 - 如何解决这个问题？ -> 记忆库


- MoCo also optimizes contrastive learning objective

$$\mathcal{L}_{q, k^+, \{k^-\}} = -\log \frac{\exp(q \cdot k^+ / \tau)}{\exp(q \cdot k^+ / \tau) + \sum_{k^-} \exp(q \cdot k^- / \tau)}$$

- After encoder is updated,
 - Momentum encoder is updated by
$$\theta_{\text{momentum}} \leftarrow m\theta_{\text{momentum}} + (1 - m)\theta$$
 - Add the current positive keys k^+ into the queue

Randomly augmented samples →





Key differences to SimCLR:

- Keep a running **queue** of keys (negative samples).
- Compute gradients and update the encoder **only through the queries**.
- Decouple min-batch size with the number of keys: can support **a large number of negative samples**.
- The key encoder is **slowly progressing** through the momentum update rules:

$$\theta_k \leftarrow m\theta_k + (1 - m)\theta_q$$

Source: [He et al., 2020](#)

“MoCo V2”

Improved Baselines with Momentum Contrastive Learning

Xinlei Chen Haoqi Fan Ross Girshick Kaiming He
Facebook AI Research (FAIR)

A hybrid of ideas from SimCLR and MoCo:

- **From SimCLR:** non-linear projection head and strong data augmentation.
- **From MoCo:** momentum-updated queues that allow training on a large number of negative samples (no TPU required!).

Source: [Chen et al., 2020](#)

- 该模型进行了消融实验，研究了非线性投影头、强数据增强和训练轮数的影响

MoCo vs. SimCLR vs. MoCo V2

Key takeaways:

- Non-linear projection head and strong data augmentation are crucial for contrastive learning.

case	unsup. pre-train				ImageNet acc.	VOC detection		
	MLP	aug+	cos	epochs		AP ₅₀	AP	AP ₇₅
supervised					76.5	81.3	53.5	58.8
MoCo v1				200	60.6	81.5	55.9	62.6
(a)	✓			200	66.2	82.0	56.4	62.6
(b)			✓	200	63.4	82.2	56.8	63.2
(c)	✓	✓		200	67.3	82.5	57.2	63.9
(d)	✓	✓	✓	200	67.5	82.4	57.0	63.6
(e)	✓	✓	✓	800	71.1	82.5	57.4	64.0

Table 1. **Ablation of MoCo baselines**, evaluated by ResNet-50 for (i) ImageNet linear classification, and (ii) fine-tuning VOC object detection (mean of 5 trials). “**MLP**”: with an MLP head; “**aug+**”: with extra blur augmentation; “**cos**”: cosine learning rate schedule.

MoCo vs. SimCLR vs. MoCo V2

case	MLP	unsup. pre-train			batch	ImageNet acc.
		aug+	cos	epochs		
MoCo v1 [6]				200	256	60.6
SimCLR [2]	✓	✓	✓	200	256	61.9
SimCLR [2]	✓	✓	✓	200	8192	66.6
MoCo v2	✓	✓	✓	200	256	67.5
<i>results of longer unsupervised training follow:</i>						
SimCLR [2]	✓	✓	✓	1000	4096	69.3
MoCo v2	✓	✓	✓	800	256	71.1

Table 2. **MoCo vs. SimCLR**: ImageNet linear classifier accuracy (**ResNet-50, 1-crop 224×224**), trained on features from unsupervised pre-training. “aug+” in SimCLR includes blur and stronger color distortion. SimCLR ablations are from Fig. 9 in [2] (we thank the authors for providing the numerical results).

mechanism	batch	memory / GPU	time / 200-ep.
MoCo	256	5.0G	53 hrs
end-to-end	256	7.4G	65 hrs
end-to-end	4096	93.0G [†]	n/a

Table 3. **Memory and time cost** in 8 V100 16G GPUs, implemented in PyTorch. [†]: based on our estimation.

Key takeaways:


- Non-linear projection head and strong data augmentation are crucial for contrastive learning.
- Decoupling mini-batch size with negative sample size allows MoCo-V2 to outperform SimCLR with smaller batch size (256 vs. 8192).
- ... all with much smaller memory footprint! (“end-to-end” means SimCLR here)

大纲

- 基于迁移学习的方法
- 自编码器
- 对比学习
- ViT & MAE预训练

视觉Transformer (ViT)

- 使用类似 BERT 的编码器进行图像表示学习
 - 通过将图像分割成 N 个图像块的序列来创建“词”的概念




- 将压平的图像块进行线性投影 $\mathbf{x}_p^i \in \mathbb{R}^{16^2 \cdot 3}$ for $i = 1, 2, \dots, N$

$$\mathbf{z}_0^i = \mathbf{x}_p^i \mathbf{E},$$

其中 $\mathbf{E} \in \mathbb{R}^{16^2 \cdot 3 \times D}$ 是线性嵌入矩阵

- 引入一个可学习的 [class] 标记，表示为 z_0^0 ，类似于 BERT 的 [CLS] 标记
- 为位置 0, 1, 2, ... N 引入可学习的一维位置嵌入，可以表示为 $E_{pos} \in \mathbb{R}^{(N+1) \times D}$




➤ 更新规则

$$\mathbf{z}_0 = [\mathbf{x}_{class}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \cdots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{pos}$$

$$\mathbf{z}'_\ell = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell$$

其中 $\text{MSA}(\cdot)$ 表示多头注意力




- ViT 变体的详细信息

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M


ViT 的监督预训练

JFT300M 包含 3 亿张带标签的图像，是谷歌为内部使用而开发的专有数据集

JFT300M 比著名的 ImageNet 数据集大得多




- 在不同的数据集上进行**监督预训练**，然后在 ImageNet 上进行微调以进行评估
 - ViT-L/16 意味着图像块大小设置为 16×16
 - BiT 指的是在 ImageNet 和辅助数据集上训练的 ResNet




- ✓ 对于小型预训练数据集，ResNet 表现更好，ViT-B 表现优于 ViT-L，这可能是由于 CNN 对图像的归纳偏置以及大型 ViT 容易过拟合
- ✓ 对于大型数据集，ViT-L 和 ViT-H 的优势比 ResNet 和 ViT-B 更为突出
- ✓ 小图像块 (16×16) 比大图像块 (32×32) 更受欢迎

- 在不同比例的 JFT-300 数据集上进行监督预训练，然后在 ImageNet 上对输出表示进行线性探测




- ✓ 结果表明，当预训练数据集足够大时，ViT-L 学习到的表示比 ResNet 更好
 - 从海量数据中学到的知识压倒了 CNN 的归纳偏置

➤ ViT-L/32 的位置嵌入的相似性



- 学习到的位置嵌入可以自己发现相关的行和列


➤ 每个头和网络深度对关注区域大小的影响。图中每个点代表16个注意力头中的一个，并显示了其在所有图像上的平均注意力距离。



- 浅层：一些头关注局部图像块，而一些头关注远距离图像块
- 深层：大多数关注远距离图像块

ViT 的 MAE 预训练

模型结构



- 基于 Transformer 的编码器和解码器
- 非对称编码器-解码器架构，即轻量级解码器
- 高掩蔽率，75% 的图像块是随机掩蔽的

训练目标：基于未掩蔽的图像块预测掩蔽的图像块


事实证明，这种预训练方法比在 ViT 上进行有监督的预训练更有效率，**所需的数据更少**

Kaiming He, et al., Masked Autoencoders are Scalable Vision Learners, CVPR 2022

输入图像块

预测结果

真实图像



设计选择

- 轻量级解码器就足够了

blocks	ft	lin
1	84.8	65.5
2	84.9	70.0
4	84.9	71.9
8	84.9	73.5
12	84.4	73.3

(a) **Decoder depth.** A deep decoder can improve linear probing accuracy.

dim	ft	lin
128	84.9	69.1
256	84.8	71.3
512	84.9	73.5
768	84.4	73.1
1024	84.3	73.1

(b) **Decoder width.** The decoder can be narrower than the encoder (1024-d).

- 解码器的深度和宽度对通过微调提高性能的影响较小
- 只有单个 transformer 块的解码器可以通过微调表现出色

- 在编码器中跳过 mask token [M]，并稍后在解码器中应用

case	ft	lin	FLOPs
encoder w/ [M]	84.2	59.6	3.3×
encoder w/o [M]	84.9	73.5	1×

(c) **Mask token.** An encoder without mask tokens is more accurate and faster (Table 2).

- 使用逐图像块归一化预测像素可提高准确性
- MAE 在仅使用裁剪增强时效果很好

case	ft	lin
pixel (w/o norm)	84.9	73.5
pixel (w/ norm)	85.4	73.9
PCA	84.6	72.3
dVAE token	85.3	71.6

(d) **Reconstruction target.** Pixels as reconstruction targets are effective.


case	ft	lin
none	84.0	65.7
crop, fixed size	84.7	73.1
crop, rand size	84.9	73.5
crop + color jit	84.3	71.9

(e) **Data augmentation.** Our MAE works with minimal or no augmentation.


- 随机图像块掩蔽优于块状和网格状掩蔽

case	ratio	ft	lin
random	75	84.9	73.5
block	50	83.9	72.3
block	75	82.8	63.9
grid	75	84.0	66.0

(f) **Mask sampling.** Random sampling works the best. See Figure 6 for visualizations.



监督预训练 vs MAE 预训练



1N1K 是 ImageNet-1K, 包含约 128 万张图像


JFT300M 包含谷歌为内部使用而开发的 3 亿张带标签的图像

- ViT-L和 ViT-H 非常大, 当以监督方式直接在小型数据集 ImageNet-1K 上训练时, 很容易导致过拟合
- 使用 MAE 预训练 ViT-large 可以有效缓解过拟合问题
- 在 **ImageNet-1K** 上使用 MAE 预训练的 ViT 表现出与在 **JFT 300M** 上使用监督预训练相似的性能

- MAE 预训练比从头开始在 ImageNet 上进行监督训练效果更好
- 在 ImageNet-1K 上进行的 MAE 预训练比在 JFT-300M 数据集上进行的监督预训练落后 4%
 - MAE 预训练中使用的图像数量远小于监督预训练中使用的图像数量 ($\sim 1\text{M}$ vs 300M)
 - MAE 预训练不需要使用任何标签信息，而监督预训练需要
 - 监督预训练优于 MAE 的性能也可能表明，在预训练阶段利用一些监督信息是有益的

- MAE 预训练 vs 其他无监督预训练，例如，MoCo 预训练
 - 在没有使用标签的 ImageNet-1K 训练数据集上进行预训练
 - 在具有标签的同一数据集上进行微调

下面显示了评估性能，其中 Scratch 表示直接从标签进行训练而不使用预训练



MAE 预训练表现最好，并且随着模型尺寸的增加，性能提升变得更大