

线性回归

对于一个拥有 n 个样本和 m 个特征的训练数据集，我们使用线性回归模型进行拟合。样本的特征矩阵为 $\mathbf{X}$ （一个 $n \times (m + 1)$ 矩阵，已包含偏置项），对应的真实值标签为向量 $\mathbf{y}$ （一个 $n \times 1$ 向量）。模型的参数为向量 $\mathbf{w}$ （一个 $(m + 1) \times 1$ 向量）。

请根据课件内容，写出以下核心公式：

1. 代价函数 (Cost Function)

请写出线性回归模型中基于**均方误差 (Mean Squared Error)** 的代价函数 $L(\mathbf{w})$ 的矩阵形式。

2. 数值解 (Normal Equation)

当代价函数 $L(\mathbf{w})$ 是凸函数时，其最优解 $\mathbf{w}^*$ 可以通过令其梯度为零找到。请写出该最优解的矩阵形式表达式（也称为正规方程解）。

3. 梯度下降 (Gradient Descent)

梯度下降是一种通过迭代来最小化代价函数的优化算法。

a. 请写出代价函数 $L(\mathbf{w})$ 关于参数 $\mathbf{w}$ 的梯度 $\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}}$ 的矩阵形式表达式。

b. 基于此梯度，请写出使用梯度下降法更新模型参数 $\mathbf{w}$ 的完整迭代公式。

对于一个拥有 n 个样本和 m 个特征的训练数据集，我们使用线性回归模型进行拟合。样本的特征矩阵为 $\mathbf{X}$ （一个 $n \times (m + 1)$ 矩阵，已包含偏置项），对应的真实值标签为向量 $\mathbf{y}$ （一个 $n \times 1$ 向量）。模型的参数为向量 $\mathbf{w}$ （一个 $(m + 1) \times 1$ 向量）。

1. 代价函数 (Cost Function)

线性回归的代价函数可以使用均方误差来衡量，其矩阵形式的公式为：

$$L(\mathbf{w}) = \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

其中 $L(\mathbf{w})$ 是代价函数， $\mathbf{X}$ 是特征矩阵， $\mathbf{w}$ 是参数列向量， $\mathbf{y}$ 是真实值标签向量， n 是训练样本的数量。

对于一个拥有 n 个样本和 m 个特征的训练数据集，我们使用线性回归模型进行拟合。样本的特征矩阵为 $\mathbf{X}$ （一个 $n \times (m + 1)$ 矩阵，已包含偏置项），对应的真实值标签为向量 $\mathbf{y}$ （一个 $n \times 1$ 向量）。模型的参数为向量 $\mathbf{w}$ （一个 $(m + 1) \times 1$ 向量）。

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = \frac{2}{n}(\mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y})$$

2. 数值解 (Normal Equation)

由于线性回归的代价函数是一个凸函数，其最优解可以通过令梯度等于零来求得。求解该方程得到的最优参数 $\mathbf{w}^*$ 的矩阵表达式为：

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

注：当样本数量 n 和特征维度 m 非常大时，矩阵求逆的计算复杂度高，计算成本非常大

对于一个拥有 n 个样本和 m 个特征的训练数据集，我们使用线性回归模型进行拟合。样本的特征矩阵为 $\mathbf{X}$ （一个 $n \times (m + 1)$ 矩阵，已包含偏置项），对应的真实值标签为向量 $\mathbf{y}$ （一个 $n \times 1$ 向量）。模型的参数为向量 $\mathbf{w}$ （一个 $(m + 1) \times 1$ 向量）。

3. 梯度下降 (Gradient Descent)

a. 代价函数梯度

代价函数 $L(\mathbf{w})$ 对参数 $\mathbf{w}$ 的梯度，其矩阵形式表达式为：

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = \frac{2}{n}(\mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y})$$

b. 参数更新公式

将上述梯度代入梯度下降的通用更新规则中，可以得到参数 $\mathbf{w}$ 的完整迭代公式：

$$\mathbf{w}_{t+1} = \mathbf{w}_t - r \cdot \frac{2}{n}(\mathbf{X}^T \mathbf{X} \mathbf{w}_t - \mathbf{X}^T \mathbf{y})$$

逻辑回归

思考题：逻辑回归中的交叉熵损失函数

题目描述：

在二分类逻辑回归中，我们通常使用交叉熵作为损失函数，并使用梯度下降法来优化模型参数。请根据课件内容，写出下列对应的公式：

1. **交叉熵损失函数：**写出单个样本的二分类交叉熵损失函数 $L(\mathbf{w})$ 的完整形式。
2. **一阶导数与梯度下降：**
 - 写出交叉熵损失函数 $L(\mathbf{w})$ 对参数 $\mathbf{w}$ 的一阶导数（梯度） $\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}}$ 的表达式。
 - 写出基于该梯度的梯度下降法（Gradient Descent）的参数更新公式。
3. **二阶导数与凸性：**
 - 写出交叉熵损失函数 $L(\mathbf{w})$ 对参数 $\mathbf{w}$ 的二阶导数（海森矩阵） $\mathbf{H}$ 的表达式。
 - 写出判断该海森矩阵半正定性的表达式，并解释为什么交叉熵损失函数是凸函数。

在二分类逻辑回归中，我们通常使用交叉熵作为损失函数，并使用梯度下降法来优化模型参数。请根据课件内容，写出下列对应的公式：

1. **交叉熵损失函数**：写出单个样本的二分类交叉熵损失函数 $L(\mathbf{w})$ 的完整形式。

1. 二分类的交叉熵损失函数

对于单个样本，二分类交叉熵损失函数的定义如下：

$$L(\mathbf{w}) = -y \log(\sigma(\mathbf{xw})) - (1 - y) \log(1 - \sigma(\mathbf{xw}))$$

其中：

- $y \in \{0, 1\}$ 是样本的真实标签。
- $\mathbf{x}$ 是输入特征向量。
- $\mathbf{w}$ 是模型的权重向量。
- $\sigma(z) = \frac{1}{1+e^{-z}}$ 是 Sigmoid 函数。

这个公式也可以写成分段函数的形式：

$$L(\mathbf{w}) = \begin{cases} -\log(\sigma(\mathbf{xw})) & \text{if } y = 1 \\ -\log(1 - \sigma(\mathbf{xw})) & \text{if } y = 0 \end{cases}$$

在二分类逻辑回归中，我们通常使用交叉熵作为损失函数，并使用梯度下降法来优化模型参数。请根据课件内容，写出下列对应的公式：

2. 一阶导数与梯度下降：

- 写出交叉熵损失函数 $L(\mathbf{w})$ 对参数 $\mathbf{w}$ 的一阶导数（梯度） $\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}}$ 的表达式。
- 写出基于该梯度的梯度下降法（Gradient Descent）的参数更新公式。

2. 二分类交叉熵损失的一阶导数以及梯度下降公式

- 一阶导数（梯度）

交叉熵损失函数对权重向量

$\mathbf{w}$ 的梯度（假设数据集大小为 N ）为：

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{N} \sum_{\ell=1}^N (\sigma(\mathbf{x}_\ell \mathbf{w}) - y_\ell) \mathbf{x}_\ell^T$$

其中，

$(\sigma(\mathbf{x}_\ell \mathbf{w}) - y_\ell)$ 被称为预测误差。

- 梯度下降更新公式

梯度下降法的参数更新规则是让参数

$\mathbf{w}$ 沿着梯度的负方向进行更新。其更新公式为：

$$\mathbf{w}_{t+1} = \mathbf{w}_t - r \cdot \frac{\partial L(\mathbf{w})}{\partial \mathbf{w}}$$

其中

r 是学习率，用于控制每次更新的步长。

在二分类逻辑回归中，我们通常使用交叉熵作为损失函数，并使用梯度下降法来优化模型参数。请根据课件内容，写出下列对应的公式：

3. 二阶导数与凸性：

- 写出交叉熵损失函数 $L(\mathbf{w})$ 对参数 $\mathbf{w}$ 的二阶导数（海森矩阵） $\mathbf{H}$ 的表达式。
- 写出判断该海森矩阵半正定性的表达式，并解释为什么交叉熵损失函数是凸函数。

3. 二分类交叉熵损失的二阶导数以及判断半正定

- 二阶导数（海森矩阵）

交叉熵损失函数的海森矩阵（Hessian Matrix）

$\mathbf{H}$ 是其对 $\mathbf{w}$ 的二阶导数，表达式如下：

$$\mathbf{H} = \frac{\partial^2 L(\mathbf{w})}{\partial \mathbf{w} \partial \mathbf{w}^T} = \mathbf{x} \mathbf{x}^T \sigma(\mathbf{x} \mathbf{w})(1 - \sigma(\mathbf{x} \mathbf{w}))$$

- 半正定性判断

为了判断海森矩阵的半正定性，我们可以对任意非零向量

$\mathbf{v}$ 计算 $\mathbf{v}^T \mathbf{H} \mathbf{v}$ ：

$$\mathbf{v}^T \mathbf{H} \mathbf{v} = \mathbf{v}^T (\mathbf{x} \mathbf{x}^T \sigma(\mathbf{x} \mathbf{w})(1 - \sigma(\mathbf{x} \mathbf{w}))) \mathbf{v} = (\mathbf{x}^T \mathbf{v})^2 \sigma(\mathbf{x} \mathbf{w})(1 - \sigma(\mathbf{x} \mathbf{w}))$$

由于

$(\mathbf{x}^T \mathbf{v})^2 \geq 0$ ，并且 Sigmoid 函数的输出范围是 $(0, 1)$ ，所以 $\sigma(\mathbf{x} \mathbf{w})(1 - \sigma(\mathbf{x} \mathbf{w})) \geq 0$ 。因此， $\mathbf{v}^T \mathbf{H} \mathbf{v} \geq 0$ 恒成立。

因为其海森矩阵是半正定的，所以交叉熵损失函数是一个凸函数。这使得它更容易被优化，梯度下降法能够保证收敛到全局最优解。

问题一 (Primal Problem): 请根据本节课件所学内容，分别写出以下三种分类器对应的**原始优化问题** (Primal Problem) 的数学表达式。

(1) 线性最大间隔分类器 (Linearly Separable) 请写出当数据线性可分时，线性最大间隔分类器所求解的最小化目标函数及其约束条件。

(2) 软线性最大间隔分类器 (Soft-margin) 当数据非线性可分时，我们引入了松弛变量 ξ_n 。请写出软间隔分类器所求解的最小化目标函数及其约束条件。

(3) 支持向量机 (SVM with Feature Map) 为了处理非线性问题，我们将原始数据 $\mathbf{x}$ 映射到高维特征空间 $\phi(\mathbf{x})$ 。请写出此时支持向量机在**特征空间**中所求解的最小化目标函数及其约束条件（即非线性化的原始问题）。

问题二 (Dual Problem): 请基于问题一中的原始优化问题，利用拉格朗日对偶性 (Lagrangian Duality)，推导并写出它们对应的**对偶优化问题**。

(1) 线性最大间隔分类器 (Linearly Separable) 请写出其对偶优化问题的最大化目标函数及其约束条件。

(2) 软线性最大间隔分类器 (Soft-margin) 请写出其对偶优化问题的最大化目标函数及其约束条件。

(3) 支持向量机 (SVM with Kernel) 请写出将特征映射 $\phi(\mathbf{x})$ 替换为核函数 $k(\mathbf{x}_n, \mathbf{x}_m)$ 后的对偶优化问题（即应用核技巧后的形式）。

问题一 (Primal Problem): 请根据本节课件所学内容, 分别写出以下三种分类器对应的**原始优化问题** (Primal Problem) 的数学表达式。

(1) 线性最大间隔分类器 (Linearly Separable) 请写出当数据线性可分时, 线性最大间隔分类器所求解的最小化目标函数及其约束条件。

(2) 软线性最大间隔分类器 (Soft-margin) 当数据非线性可分时, 我们引入了松弛变量 ξ_n 。请写出软间隔分类器所求解的最小化目标函数及其约束条件。

(3) 支持向量机 (SVM with Feature Map) 为了处理非线性问题, 我们将原始数据 $\mathbf{x}$ 映射到高维特征空间 $\phi(\mathbf{x})$ 。请写出此时支持向量机在**特征空间**中所求解的最小化目标函数及其约束条件 (即非线性化的原始问题) 。

(1) 线性最大间隔分类器

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_\ell (\mathbf{w}^T \mathbf{x}_\ell + b) \geq 1, \quad \text{for } \ell = 1, 2, \dots, N \end{aligned}$$

(2) 软线性最大间隔分类器

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y_n (\mathbf{w}^T \mathbf{x}_n + b) \geq 1 - \xi_n, \quad \text{for } n = 1, 2, \dots, N \\ & \xi_n \geq 0, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

(3) 支持向量机 (SVM with Feature Map)

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) \geq 1 - \xi_n, \quad \text{for } n = 1, 2, \dots, N \\ & \xi_n \geq 0, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

问题二 (Dual Problem): 请基于问题一中的原始优化问题，利用拉格朗日对偶性 (Lagrangian Duality)，推导并写出它们对应的**对偶优化问题**。

(1) 线性最大间隔分类器 (Linearly Separable) 请写出其对偶优化问题的最大化目标函数及其约束条件。

(1) 线性最大间隔分类器

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_\ell (\mathbf{w}^T \mathbf{x}_\ell + b) \geq 1, \quad \text{for } \ell = 1, 2, \dots, N \end{aligned}$$

(1) 线性最大间隔分类器 推导思路：

1. 构建拉格朗日函数： $\mathcal{L}(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{\ell=1}^N a_\ell [y_\ell (\mathbf{w}^T \mathbf{x}_\ell + b) - 1]$, 其中 $a_\ell \geq 0$ 。

⌘ ⌘

2. 令 $\mathcal{L}$ 对 $\mathbf{w}$ 和 b 的偏导为 0： ⌘

- $\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{\ell=1}^N a_\ell y_\ell \mathbf{x}_\ell = 0 \implies \mathbf{w} = \sum_{\ell=1}^N a_\ell y_\ell \mathbf{x}_\ell$ ⌘
- $\frac{\partial \mathcal{L}}{\partial b} = - \sum_{\ell=1}^N a_\ell y_\ell = 0 \implies \sum_{\ell=1}^N a_\ell y_\ell = 0$ ⌘

3. 将上述结果代回 $\mathcal{L}$ ，得到对偶函数 $g(\mathbf{a})$ 。 ⌘

对偶问题：

$$\begin{aligned} \max_{\mathbf{a}} \quad & g(\mathbf{a}) = \sum_{\ell=1}^N a_\ell - \frac{1}{2} \sum_{\ell=1}^N \sum_{j=1}^N a_\ell a_j y_\ell y_j \mathbf{x}_\ell^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{\ell=1}^N a_\ell y_\ell = 0 \\ & a_\ell \geq 0, \quad \text{for } \ell = 1, 2, \dots, N \end{aligned}$$

(2) 软线性最大间隔分类器 (Soft-margin) 当数据非线性可分时，我们引入了松弛变量 ξ_n 。请写出软间隔分类器所求解的最小化目标函数及其约束条件。

(2) 软线性最大间隔分类器

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1 - \xi_n, \quad \text{for } n = 1, 2, \dots, N \\ & \xi_n \geq 0, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

(2) 软线性最大间隔分类器 推导思路：

1. 构建拉格朗日函数 (引入两组乘子 $a_n \geq 0$ 和 $r_n \geq 0$) : $\mathcal{L}(\mathbf{w}, b, \xi, \mathbf{a}, \mathbf{r}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n - \sum_{n=1}^N a_n [y_n(\mathbf{w}^T \mathbf{x}_n + b) - 1 + \xi_n] - \sum_{n=1}^N r_n \xi_n$
2. 令 $\mathcal{L}$ 对 $\mathbf{w}, b$ 和 ξ_n 的偏导为 0:
 - $\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{n=1}^N a_n y_n \mathbf{x}_n = 0 \implies \mathbf{w} = \sum_{n=1}^N a_n y_n \mathbf{x}_n$
 - $\frac{\partial \mathcal{L}}{\partial b} = - \sum_{n=1}^N a_n y_n = 0 \implies \sum_{n=1}^N a_n y_n = 0$
 - $\frac{\partial \mathcal{L}}{\partial \xi_n} = C - a_n - r_n = 0 \implies C = a_n + r_n$
3. 由于 $r_n \geq 0$, 约束 $C = a_n + r_n$ 等价于 $a_n \leq C$ 。
4. 代回 $\mathcal{L}$ 得到与(1)中形式相同的 $g(\mathbf{a})$ 。

对偶问题：

$$\begin{aligned} \max_{\mathbf{a}} \quad & g(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m y_n y_m \mathbf{x}_n^T \mathbf{x}_m \\ \text{s.t.} \quad & \sum_{n=1}^N a_n y_n = 0 \\ & 0 \leq a_n \leq C, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

(3) 支持向量机 (SVM with Feature Map) 为了处理非线性问题，我们将原始数据 $\mathbf{x}$ 映射到高维特征空间 $\phi(\mathbf{x})$ 。请写出此时支持向量机在**特征空间**中所求解的最小化目标函数及其约束条件（即非线性化的原始问题）。

(3) 支持向量机 (SVM with Feature Map)

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n \\ \text{s.t.} \quad & y_n(\mathbf{w}^T \phi(\mathbf{x}_n) + b) \geq 1 - \xi_n, \quad \text{for } n = 1, 2, \dots, N \\ & \xi_n \geq 0, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

(3) 支持向量机 (SVM with Kernel) 推导思路：

- 1. 基于(2)的推导，将 $\mathbf{x}_n$ 替换为特征映射 $\phi(\mathbf{x}_n)$ 。
- 2. 对偶目标函数中的内积项 $\mathbf{x}_n^T \mathbf{x}_m$ 变为 $\phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m)$ 。
- 3. 应用核技巧（Kernel Trick），用核函数 $k(\mathbf{x}_n, \mathbf{x}_m)$ 替换内积 $\phi(\mathbf{x}_n)^T \phi(\mathbf{x}_m)$ 。

对偶问题：

$$\begin{aligned} \max_{\mathbf{a}} \quad & g(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m y_n y_m k(\mathbf{x}_n, \mathbf{x}_m) \\ \text{s.t.} \quad & \sum_{n=1}^N a_n y_n = 0 \\ & 0 \leq a_n \leq C, \quad \text{for } n = 1, 2, \dots, N \end{aligned}$$

神经网络

任务一：简单神经网络图像分类

任务：构建一个简单的三层 MLP，在两个经典的图像分类数据集（Fashion-MNIST 和 CIFAR-10）上进行训练和测试。

目标：掌握 [Pytorch](#) 构建、训练和评估神经网络的基本流程。

参考：<https://docs.pytorch.org/tutorials/beginner/basics/intro.html>

任务二：使用预训练 ResNet-50 模型进行图像分类

任务：阅读 [ResNet](#) 论文，使用一个在 ImageNet 数据集上预训练好的 ResNet-50 模型在 ImageNet 数据集上进行测试。

模型：<https://huggingface.co/microsoft/resnet-50>

目标：理解 [ResNet](#) 的核心思想。

参考：<https://arxiv.org/pdf/1512.03385>

（可选）任务三：使用预训练 ResNet-50 模型进行目标检测（包含分类和回归任务）

任务：学习目标检测任务，理解 [mAP](#) 指标，使用预训练模型复现 [ResNet](#) 论文中的目标检测实验结果（Section 4.3）。


参考：<https://arxiv.org/pdf/1506.01497>

参考实现：<https://github.com/rbgirshick/py-faster-rcnn>、<https://github.com/open-mmlab/mmdetection>


梯度下降法、训练优化、非线性化、过拟合、正则化

决策树

day	outlook	temperature	humidity	wind	play
1	sunny	hot	high	weak	no
2	sunny	hot	high	strong	no
3	overcast	hot	high	weak	yes
4	rain	mild	high	weak	yes
5	rain	cool	normal	weak	yes
6	rain	cool	normal	strong	no
7	overcast	cool	normal	strong	yes
8	sunny	mild	high	weak	no
9	sunny	cool	normal	weak	yes
10	rain	mild	normal	weak	yes
11	sunny	mild	normal	strong	yes
12	overcast	mild	high	strong	yes
13	overcast	hot	normal	weak	yes
14	rain	mild	high	strong	no




如何构建一个决策树？



熵、条件熵、信息增益、决策树构建


集成学习

Bagging



Parallel

Boosting



Sequential

Bagging、Boosting

K-Means

任务一：手动实现 K-Means 算法




数据：基于如下数据生成一个更复杂的2D数据集，可以自由控制簇的数量、分散程度和形状，示例代码如下所示：

```
from sklearn.datasets import make_blobs
X_main, y_main = make_blobs(n_samples=300, centers=4, cluster_std=0.7, random_state=42)
```

任务二：手动实现 K-Means++ 初始化


背景：基础 K-Means 对初始点非常敏感，容易陷入局部最优解。K-Means++ 是一种更智能的初始化方法。

对比分析：分别使用“随机初始化”和“K-Means++ 初始化”运行算法多次，比较结果的均值和方差，验证方法的有效性



K-Means算法、Soft K-Means思想

PCA in a nutshell



角度 1: 最小化重构误差

角度 2: 最大化方差

角度 3: 奇异值分解 (SVD)

EM 算法

- 算法

E 步: 计算期望

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)}) = \mathbb{E}_{p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})} [\log p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta})]$$


M 步: 更新参数

$$\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$$


- EM 算法的关键要素

- 1) 后验分布 $p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})$
- 2) 联合分布对数 $\log p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta})$ 关于后验概率的期望
- 3) 最大化


文本表征学习、视觉表征学习、多模态学习



BERT



SimCLR



CLIP

词向量、BERT、对比学习、SimCLR、CLIP

任务一：LLM 数学推理评测 (GSM8K)

- **数据集：** <https://huggingface.co/datasets/openai/gsm8k> (GSM8K, Grade School Math 8K)
- **测试集规模：** 为了节省算力，请从 Test set 中随机抽取 50 条数据进行评测
- **模型要求：** 选择一个 7B 参数量或者蒸馏后更小参数量的开源模型（推荐 Qwen2.5-7B-Instruct, Llama-2-7B）
- **任务：** 构建 Pipeline，输入问题，让模型输出推理过程和答案，并自动提取答案与 Ground Truth 对比计算准确率

任务二：MLLM 多模态科学问答 (ScienceQA)

- **数据集：** <https://huggingface.co/datasets/derek-thomas/ScienceQA> (ScienceQA)
- **筛选条件：** 仅筛选包含 Image (图片) 信息的题目（即 image 字段不为空的样本）。
- **测试集规模：** 为了节省算力，请从 Test set 中随机抽取 50 条数据进行评测
- **模型要求：** 选择一个 7B 参数量或者蒸馏后的开源多模态模型（推荐 Qwen2-VL-7B-Instruct 或 LLaVA-v1.5-7b）
- **任务：** 输入“图片 + 问题 + 选项”，让模型选择正确选项（A/B/C/D），计算准确率

补充说明：

- 要求说明所选择模型的结构（根据该模型的原论文）
- 为了节省推理资源可以选择 4-bit 量化推理（例如 <https://github.com/aahouzi/llama2-chatbot-cpu>）
- Don't just call the API, understand the pipeline.

GPT、CLIP、LLM、MLLM