



# 聚类 K-Means、线性降维 PCA

主讲人：林惊


# 聚类大纲

---

- 聚类简介
- $K$ -Means

# 什么是聚类？

- 给定一组数据实例  $\{\mathbf{x}^{(i)}\}_{i=1}^N$ ，聚类就是如何将它们分成不同的簇



- 目标：
  - 簇内实例具有高相似度
  - 簇间实例具有低相似度

# 相似性准则很重要

- 不同的相似性准则可能导致不同的结果



相似还是不相似？



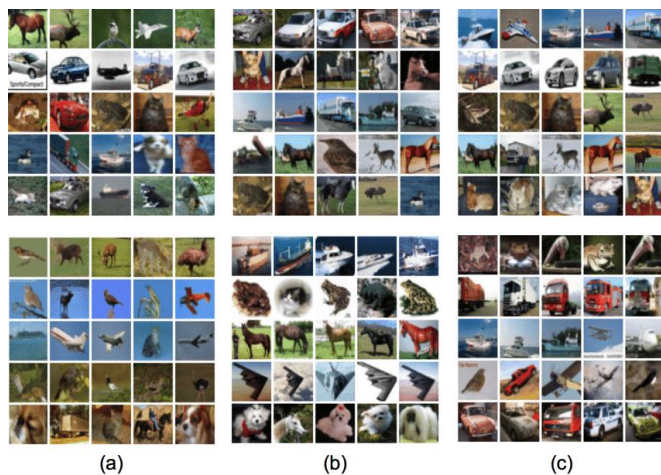
准则1：身份

准则2：眼镜



# 实际应用

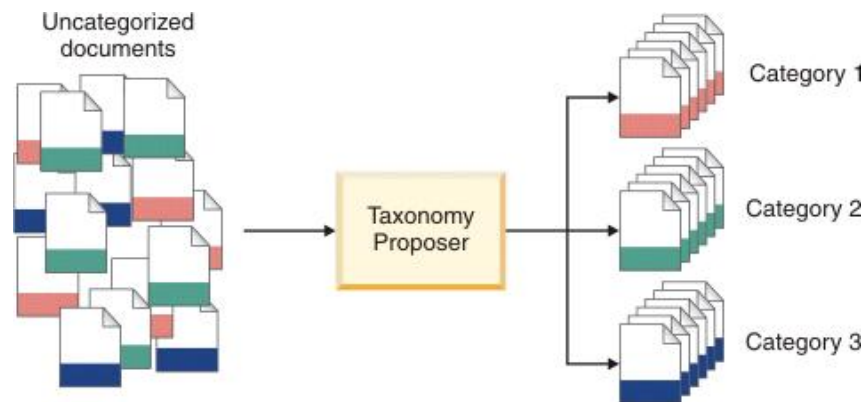
- 图像分组



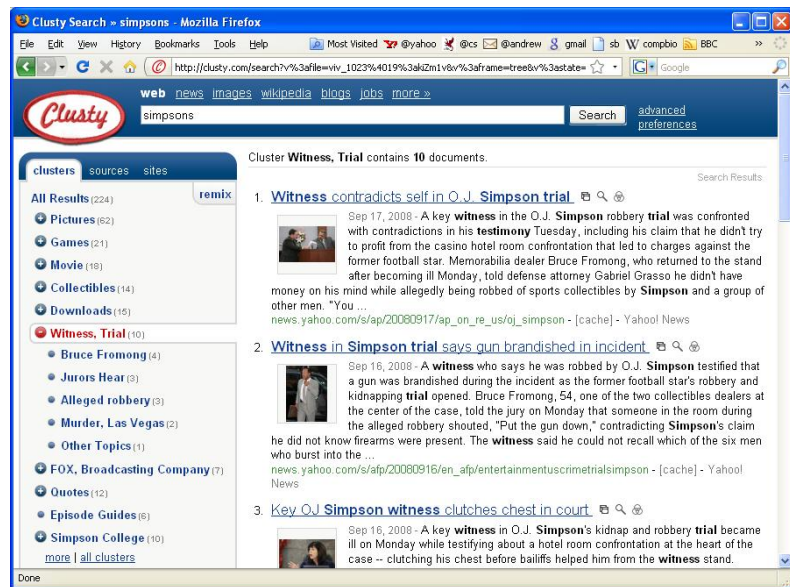
- 图像分割




- 自动将语义相似的文档分组在一起




- 网络搜索结果聚类




- 社交网络分析



- 基因表达数据聚类



- 市场细分



# 聚类大纲


---

- 聚类简介
- K-Means



# K-均值算法


- 指定  $K$  个中心  $\mu_k$ , 其中  $k = 1, \dots, K$ , 然后评估每个数据点  $\mathbf{x}^{(n)}$  与所有中心  $\mu_k$  之间的距离



- 数据点  $\mathbf{x}^{(n)}$  被分配给距离其最近的簇  $k$

$$r_{nk} = \begin{cases} 1, & \text{if } k = \arg \min_j \|\mathbf{x}^{(n)} - \mu_j\|^2 \\ 0, & \text{otherwise} \end{cases}$$

- 使用簇内样本的均值来更新中心



两个问题：

- 1) 这个算法到底在做什么？
- 2) 这个算法能保证收敛吗？

$$\mu_k \leftarrow \frac{\sum_{n=1}^N r_{nk} \mathbf{x}_n}{\sum_{n=1}^N r_{nk}}$$

- 重复上述分配和中心更新步骤

# 收敛性保证

- 定义一个目标函数，它是所有数据实例与其对应中心之间距离的总和：

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}^{(n)} - \boldsymbol{\mu}_k\|^2$$

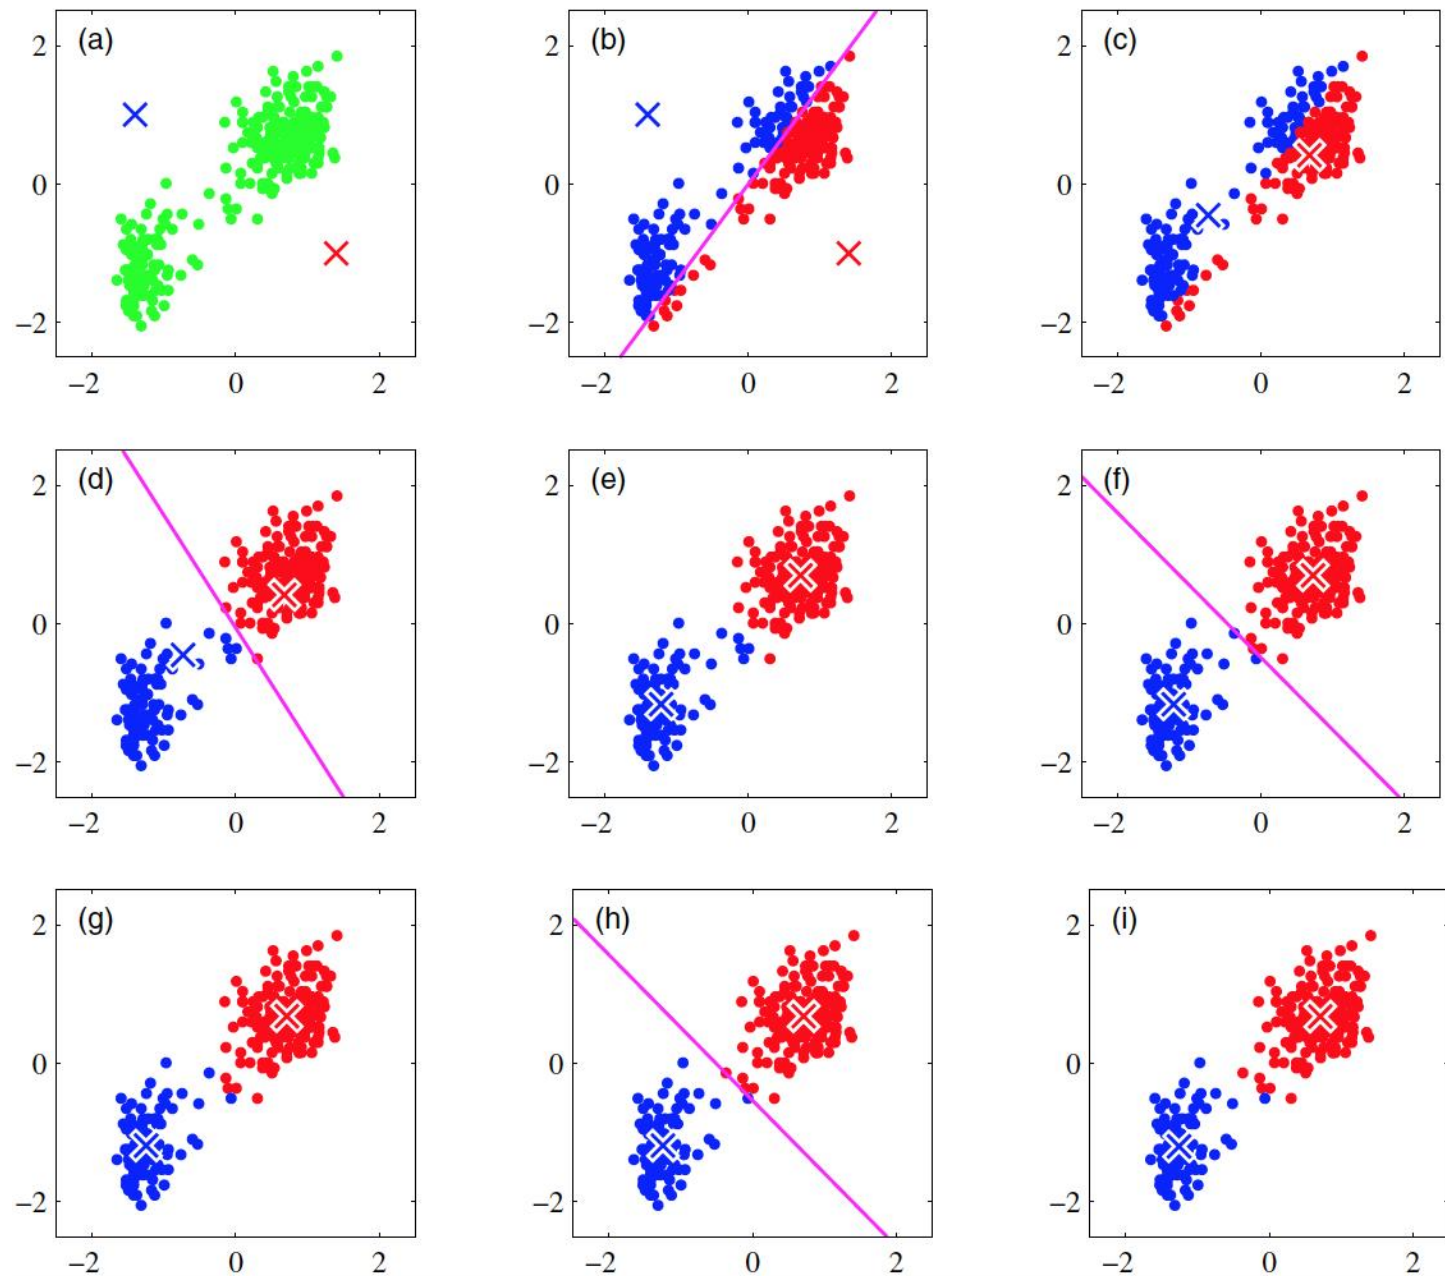
- $K$ -均值可以通过以交替方式更新  $\mathbf{r}_n$  和  $\boldsymbol{\mu}_k$  的以下优化问题得到：

$$\min_{\mathbf{r}_n, \boldsymbol{\mu}_k} J$$

$$\text{s. t. : } \mathbf{r}_n \in \text{onehot vector} \quad \forall n \text{ \& } k$$




其中， $\mathbf{r}_n \triangleq [r_{n1}, r_{n2}, \dots, r_{nK}]$  需为独热向量

- 总距离  $J$  单调递减，因此可以保证  $K$ -均值算法收敛




# 问题：簇的数量

- 如何设置  $K$  的值对于最终的聚类结果至关重要








- 随着簇数量  $K$  的增加，距离  $J$  被确定为递减。因此， $K$  不能通过最小化  $J$  来确定



- 1) 一种可能的方法是选择拐点（这里  $K=2$ ）
- 2) 另一种可能的方法是根据下游应用的性能来确定最佳的  $K$  值

# 问题：初始化

- $K$ -均值的性能也高度依赖于初始中心点



## 1) 随机方法

- 随机选择数据实例作为初始化
- 问题：可能会选择相邻的实例

## 2) 基于距离的方法

- 从一个随机数据实例开始
- 选择距离现有中心最远的点
- 问题：可能会选择离群值

## 3) 随机 + 距离方法

- 从一个随机数据实例开始
- 从其余距离现有中心较远的实例中随机选择下一个中心

# 问题：硬分配

- 硬分配

一个数据实例要么属于某个簇，要么不属于，这种分配方式是确定性的，即  $r_n$  必须是一个独热向量

- 软  $K$ -均值

软  $K$ -均值不是确定性地将  $\mathbf{x}^{(n)}$  分配给某个簇，而是以软性方式进行分配

$\beta$  控制了分布的尖锐程度


$$r_{nk} = \frac{e^{-\beta \|\mathbf{x}^{(n)} - \boldsymbol{\mu}_k\|^2}}{\sum_{i=1}^K e^{-\beta \|\mathbf{x}^{(n)} - \boldsymbol{\mu}_i\|^2}}$$

$$\boldsymbol{\mu}_k \leftarrow \frac{\sum_{n=1}^N r_{nk} \mathbf{x}_n}{\sum_{n=1}^N r_{nk}}$$

$r_{nk}$  可以被解释为数据点  $\mathbf{x}^{(n)}$  属于簇  $k$  的概率


# 其他问题

- 对离群值敏感



- 圆形形状

欧氏距离意味着边界只能是球形的。当簇具有不规则形状时，性能会很差





# 课堂小结

---

- 聚类的目标——簇内高相似、簇间低相似
- K-Means的算法
  - 算法过程
  - 等价的优化目标函数
  - 存在的问题，如：簇数量的确定、初始化、硬分配等
- 软K-Means

# 线性降维PCA大纲

---

- 动机
- 视角 1: 最小化重构误差
- 视角 2: 最大化方差
- 视角 3: 奇异值分解 (SVD)
- PCA的其他应用

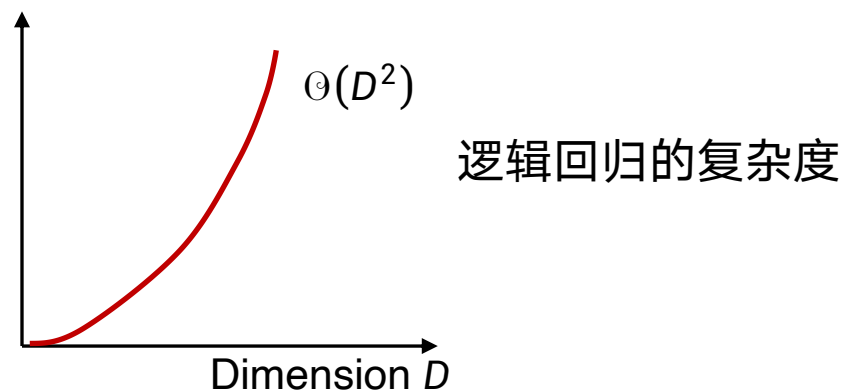
# 动机

- 许多类型数据的维度非常高，例如下面图像的维度高达

$$256 \times 256 = 65536$$




- 如果我们直接在原始数据上工作，后续任务（例如，分类）的复杂性可能会非常高。




## 降低数据的维度为什么可行？

- 高维数据通常近似存在于一个低维的内在空间上



3维数据近似存在于一个2维平面上




2维数据近似存在于一个1维直线上

关键在于如何找到主方向，从而使得数据样本的表示误差尽可能小

- 对于真实世界的数据，也可以用低维来表示

例如：如果找到合适的“方向”，人脸可以用很少的几个值很好地表示



$$\mathbf{x} \approx \boldsymbol{\mu}_0 + a_1 \boldsymbol{\mu}_1 + \cdots + a_7 \boldsymbol{\mu}_7$$

具有65536个值的原始图像  $\mathbf{x}$  可以仅用7个值  $a_1, \cdots a_7$  表示



# 线性降维PCA大纲

---

- 动机
- 视角 1：最小化重构误差
- 视角 2：最大化方差
- 视角 3：奇异值分解（SVD）
- PCA的其他应用

# 新方向下的样本重表示

- 如何在高维空间中表示正交方向？

一组满足以下条件的向量  $\mathbf{u}_i$

$$\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$

如果  $i = j$  ,  $\delta_{ij} = 1$ ; 否则  $\delta_{ij} = 0$

**定理：** 在给定  $M$  个正交方向  $\{\mathbf{u}_i\}_{i=1}^M$  的情况下，对数据样本  $\mathbf{x}$  的**最佳近似**为

$$\tilde{\mathbf{x}} = a_1 \mathbf{u}_1 + a_2 \mathbf{u}_2 + \cdots + a_M \mathbf{u}_M$$

其中  $a_i$  等于

$$a_i = \mathbf{u}_i^T \mathbf{x}$$

证明:

$$\begin{aligned}\|\mathbf{x} - \tilde{\mathbf{x}}\|^2 &= \left\| \mathbf{x} - \sum_{i=1}^M a_i \mathbf{u}_i \right\|^2 \\ &= \|\mathbf{x}\|^2 - 2 \sum_{i=1}^M a_i \mathbf{u}_i^T \mathbf{x} + \sum_{i=1}^M a_i^2\end{aligned}$$


若  $i \neq j$ ,  $\mathbf{u}_i^T \mathbf{u}_j = 0$ ; 若  $i = j$ ,  $\mathbf{u}_i^T \mathbf{u}_j = 1$

这是一个二次函数, 当  $a_i = \mathbf{u}_i^T \mathbf{x}$  时可以最小化

给定方向  $\{\mathbf{u}_i\}_{i=1}^M$ , 最佳系数为  $a_i = \mathbf{u}_i^T \mathbf{x}$ 。但是如何找到最佳方向仍然未知

# 寻找最佳方向

- **目标：** 给定来自  $\mathbb{R}^D$  的数据样本  $\{\mathbf{x}^{(n)}\}_{n=1}^N$ ，找到  $M$  个正交方向  $\mathbf{u}_i$ ，使得原始数据可以在这些方向下得到最佳表示



$$\mathbf{x}^{(n)} \approx \sum_{i=1}^M a_i^{(n)} \mathbf{u}_i$$

- 如果假设给定了最佳方向  $\{\mathbf{u}_i\}_{i=1}^M$ ，那么最佳系数  $a_i^{(n)}$  是什么？

$$a_i^{(n)} = \mathbf{u}_i^T \mathbf{x}^{(n)}$$



不直接表示数据  $\mathbf{x}^{(n)}$ ，我们首先将数据中心化到原点，即从每个数据点  $\mathbf{x}^{(n)}$  中减去其均值

$$\mathbf{x}^{(n)} - \bar{\mathbf{x}}, \quad \text{其中 } \bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}^{(n)}$$

- 现在的目标可以描述为——最小化  $\mathbf{x}^{(n)} - \bar{\mathbf{x}}$  与其在方向  $\{\mathbf{u}_i\}_{i=1}^M$  下的最佳表示  $\sum_{i=1}^M a_i^{(n)} \mathbf{u}_i$  之间的误差

$$E \triangleq \frac{1}{N} \sum_{n=1}^N \left\| (\mathbf{x}^{(n)} - \bar{\mathbf{x}}) - \sum_{i=1}^M a_i^{(n)} \mathbf{u}_i \right\|^2$$

即：解如下优化问题

$$\text{Min}_{a_i^{(n)}, \mathbf{u}_i} E,$$

其中系数  $a_i^{(n)}$  的最佳取值已经知道等于

$$a_i^{(n)} = \mathbf{u}_i^T (\mathbf{x}^{(n)} - \bar{\mathbf{x}})$$

- 化简重建误差  $E$

a) 注意到  $\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$ ，重建误差  $E = \frac{1}{N} \sum_{n=1}^N \|(\mathbf{x}^{(n)} - \bar{\mathbf{x}}) - \sum_{i=1}^M a_i^{(n)} \mathbf{u}_i\|^2$  可表示成

$$E = \frac{1}{N} \left( \sum_{n=1}^N \|\mathbf{x}^{(n)} - \bar{\mathbf{x}}\|^2 - 2 \sum_{n=1}^N \sum_{i=1}^M a_i^{(n)} (\mathbf{x}^{(n)} - \bar{\mathbf{x}})^T \mathbf{u}_i + \sum_{n=1}^N \sum_{i=1}^M (a_i^{(n)})^2 \right)$$

b) 代入  $a_i^{(n)} = \mathbf{u}_i^T (\mathbf{x}^{(n)} - \bar{\mathbf{x}})$ ，可得

$$E = \frac{1}{N} \sum_{n=1}^N \|\mathbf{x}^{(n)} - \bar{\mathbf{x}}\|^2 - \sum_{i=1}^M \mathbf{u}_i^T \underbrace{\frac{1}{N} \sum_{n=1}^N (\mathbf{x}^{(n)} - \bar{\mathbf{x}})(\mathbf{x}^{(n)} - \bar{\mathbf{x}})^T}_{\triangleq \mathbf{S}} \mathbf{u}_i$$

c) 将其写成矩阵形式给出

$$E = \frac{1}{N} \|\mathbf{X} - \bar{\mathbf{X}}\|_F^2 - \sum_{i=1}^M \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i$$

其中  $\mathbf{X} \triangleq [\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}]$ ,  $\|\cdot\|_F$  表示Frobenius 范数

- 在约束  $\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$  下, 最小化  $E = \frac{1}{N} \|\mathbf{X} - \bar{\mathbf{X}}\|_F^2 - \frac{1}{N} \sum_{i=1}^M \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i$  可等价表示为

$$\max_{\mathbf{u}_1 \cdots \mathbf{u}_M} \sum_{i=1}^M \mathbf{u}_i^T \mathbf{S} \mathbf{u}_i$$

$$\text{s. t. : } \mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$$

- 考虑  $M = 1$  的简单情况。问题简化为：

$$\begin{aligned} \max_{\mathbf{u}_1} \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 \\ \text{s. t. : } \mathbf{u}_1^T \mathbf{u}_1 = 1 \end{aligned}$$

- 这等价于最大化

$$\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 - \lambda(\mathbf{u}_1^T \mathbf{u}_1 - 1)$$

- 对  $\mathbf{u}_1$  求导并将其设置为 0 给出

$$\mathbf{S} \mathbf{u}_1 = \lambda \mathbf{u}_1,$$

从中我们可以看到  $\mathbf{u}_1$  应该是 **S** 的特征向量

- 可以进一步验证，对应于最大特征值的特征向量可以最大化  $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1$

- 对于  $M = 2$  的情况，问题变为

$$\max_{\mathbf{u}_1, \mathbf{u}_2} \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2$$

$$\text{s. t. : } \mathbf{u}_1^T \mathbf{u}_1 = 1, \mathbf{u}_2^T \mathbf{u}_2 = 1, \mathbf{u}_1^T \mathbf{u}_2 = 0$$

- 这等价于最大化

$$\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 - \lambda_1 (\mathbf{u}_1^T \mathbf{u}_1 - 1) + \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2 - \lambda_2 (\mathbf{u}_2^T \mathbf{u}_2 - 1)$$

约束为  $\mathbf{u}_1^T \mathbf{u}_2 = 0$

- 对  $\mathbf{u}_1$  和  $\mathbf{u}_2$  求导并将其设置为 0 给出

$$\mathbf{S} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1, \quad \mathbf{S} \mathbf{u}_2 = \lambda_2 \mathbf{u}_2,$$

⇒  $\mathbf{u}_1$  和  $\mathbf{u}_2$  必须是  $\mathbf{S}$  的特征向量

⇒ 可以看出，为了最大化  $\mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 + \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2$ ， $\mathbf{u}_1$  和  $\mathbf{u}_2$  必须是对应于两个最大特征值的特征向量

对于  $M > 1$  的情况，方向  $u_i$  是  $S$  对应于最大的  $M$  个特征值的特征向量

$$A = X - \bar{X}$$

问题：对于  $i \neq j$ ， $S$  的特征向量  $u_i$  是否满足  $u_i^T u_j = 0$ ？

- 对于任何  $D \times D$  实对称矩阵（例如  $S \triangleq AA^T$ ），它都有  $D$  个彼此正交的特征向量
- 对于每个  $S \triangleq AA^T$ ，它可以分解为

$$S = U\Lambda U^T$$

其中  $U$  由  $S$  的特征向量组成，且  $UU^T = I$ ； $\Lambda$  是由  $S$  的特征值组成的对角矩阵

# 示例

输入数据：每张人脸  
图像是一个数据点



前 25 个主方向



$$x \approx \bar{x} + a_1 u_1 + \cdots + a_7 u_7$$

# 线性降维PCA大纲


---

- 动机
- 视角1：最小化重构误差
- 视角2：最大化方差
- 视角3：奇异值分解（SVD）
- 主成分分析（PCA）的其他应用



# 问题公式化

- **目标:** 给定一个数据集  $\{\mathbf{x}^{(n)}\}_{n=1}^N$ ，找到正交方向  $\{\mathbf{u}_k\}_{k=1}^M$ ，使得数据在这些方向上的投影的**方差**最大化



最大化方差相当于**尽可能多地保留原始数据的信息**

- 对于第一个方向  $\mathbf{u}_1$ ，我们希望沿方向  $\mathbf{u}_1$  投影的数据的方差最大化，即  $\{\mathbf{u}_1^T \mathbf{x}^{(n)}\}_{n=1}^N$  最大化

➤ 方差表达式

$$\begin{aligned} var &= \frac{1}{N} \sum_{n=1}^N \left( \mathbf{u}_1^T (\mathbf{x}^{(n)} - \bar{\mathbf{x}}) \right)^2 \\ &= \mathbf{u}_1^T \frac{1}{N} \sum_{n=1}^N (\mathbf{x}^{(n)} - \bar{\mathbf{x}}) (\mathbf{x}^{(n)} - \bar{\mathbf{x}})^T \mathbf{u}_1 \\ &= \mathbf{u}_1^T \mathbf{S} \mathbf{u}_1 \end{aligned}$$

- 如先前证明的，在满足  $\mathbf{u}_1^T \mathbf{u}_1 = 1$  的约束条件下，当  $\mathbf{u}_1$  是  $\mathbf{S}$  对应于最大特征值的特征向量时，方差最大化

- 对于第二个方向  $\mathbf{u}_2$ ，它也应该最大化方差

$$\text{var} = \mathbf{u}_2^T \mathbf{S} \mathbf{u}_2,$$

但应满足约束条件  $\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$ ，即：

$$\mathbf{u}_2^T \mathbf{u}_2 = 1 \quad \mathbf{u}_1^T \mathbf{u}_2 = 0$$

- 由于  $\mathbf{u}_1$  是对应于最大特征值的特征向量，可以证明  $\mathbf{u}_2$  是  $\mathbf{S}$  对应于第二大特征值的特征向量

$\mathbf{u}_i$  是  $\mathbf{S} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}^{(n)} - \bar{\mathbf{x}})(\mathbf{x}^{(n)} - \bar{\mathbf{x}})^T$  的对应于第  $i$  大特征值的特征向量

# 线性降维PCA大纲


---

- 动机
- 角度 1：最小化重构误差
- 角度 2：最大化方差
- 视角 3：奇异值分解（SVD）
- PCA的其他应用

# 奇异值分解 (SVD)

- 对于任何  $M \times N$  矩阵  $\mathbf{A}$ ，它总是可以分解为

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$



- $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_M]$ 、 $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_N]$ ，其中  $\mathbf{u}_i$  和  $\mathbf{v}_i$  分别是  $\mathbf{A}\mathbf{A}^T$  和  $\mathbf{A}^T\mathbf{A}$  的第  $i$  个特征向量，并且  $\mathbf{u}_i^T \mathbf{u}_j = \delta_{ij}$ ， $\mathbf{v}_i^T \mathbf{v}_j = \delta_{ij}$
- $\mathbf{\Sigma}$  仅在对角线上有非零值，这些值是  $\mathbf{A}\mathbf{A}^T$  或  $\mathbf{A}^T\mathbf{A}$  的特征值的平方根（ $\mathbf{A}\mathbf{A}^T$  和  $\mathbf{A}^T\mathbf{A}$  的非零特征值相同）

对角元素  $\Sigma_{ii}$  称为**奇异值**，并按降序排列

- 因为  $\Sigma$  仅在对角线上有非零值，所以  $A$  可以表示为

$$A = \sum_{i=1}^r \Sigma_{ii} u_i v_i^T = U' \Sigma' V'^T$$

其中  $u_i$  和  $v_i$  是  $U$  和  $V$  的第  $i$  列；  $r$  是  $\Sigma$  中非零对角元素的数量

The diagram illustrates the matrix decomposition  $A = U' \Sigma' V'^T$ . It shows a gray matrix  $A$  of size  $M \times N$  being equal to the product of a blue and green matrix  $U'$  of size  $M \times r$ , a small square matrix  $\Sigma'$  of size  $r \times r$  with non-zero elements on the diagonal, and a purple matrix  $V'^T$  of size  $r \times N$ .

Below the diagram, the dimensions and a numerical example are provided:

$A$ $M \times N$	$=$	$U'$ $M$ $\times r$	$\times$	$\Sigma'$ $r$ $\times r$	$\times$	$V'^T$ $r$ $\times N$
$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 3 & 3 & 3 & 0 & 0 \\ 4 & 4 & 4 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 2 & 0 & 4 & 4 \\ 0 & 0 & 0 & 5 & 5 \\ 0 & 1 & 0 & 2 & 2 \end{bmatrix}$	$=$	$\begin{bmatrix} 0.13 & 0.02 & -0.01 \\ 0.41 & 0.07 & -0.03 \\ 0.55 & 0.09 & -0.04 \\ 0.68 & 0.11 & -0.05 \\ 0.15 & -0.59 & 0.65 \\ 0.07 & -0.73 & -0.67 \\ 0.07 & -0.29 & 0.32 \end{bmatrix}$	$\times$	$\begin{bmatrix} 12.4 & 0 & 0 \\ 0 & 9.5 & 0 \\ 0 & 0 & 1.3 \end{bmatrix}$	$\times$	$\begin{bmatrix} 0.56 & 0.59 & 0.56 & 0.09 & 0.09 \\ 0.12 & -0.02 & 0.12 & -0.69 & -0.69 \\ 0.40 & -0.80 & 0.40 & 0.09 & 0.09 \end{bmatrix}$

- 在  $\mathbf{A}$  的奇异值分解 (SVD) 中, 向量  $\mathbf{u}_i$  是矩阵  $\mathbf{A}\mathbf{A}^T$  对应于其第  $i$  大特征值的特征向量
- 通过设置  $\mathbf{A} = \tilde{\mathbf{X}}$ , 其中  $\tilde{\mathbf{X}} \triangleq [\mathbf{x}^{(1)} - \bar{\mathbf{x}}, \mathbf{x}^{(2)} - \bar{\mathbf{x}}, \dots, \mathbf{x}^{(N)} - \bar{\mathbf{x}}]$ , 我们可以看到

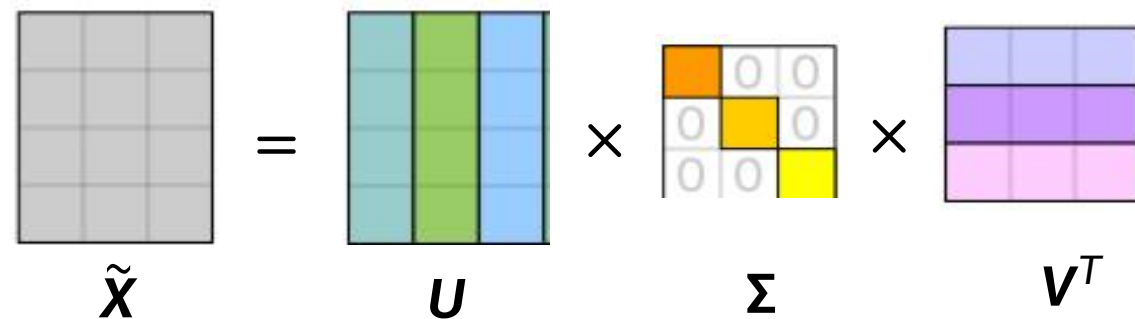
$$\begin{aligned}\tilde{\mathbf{X}}\tilde{\mathbf{X}}^T &= \sum_{n=1}^N (\mathbf{x}^{(n)} - \bar{\mathbf{x}})(\mathbf{x}^{(n)} - \bar{\mathbf{x}})^T \\ &= \mathbf{N} \cdot \mathbf{S}\end{aligned}$$

$\Rightarrow \tilde{\mathbf{X}}\tilde{\mathbf{X}}^T$  的特征向量与矩阵  $\mathbf{S}$  相同

通过对  $\tilde{\mathbf{X}}$  执行 SVD, 可以直接获得数据  $\{\mathbf{x}^{(n)}\}_{n=1}^N$  的主方向, 这些主方向是矩阵  $\mathbf{U}$  的列

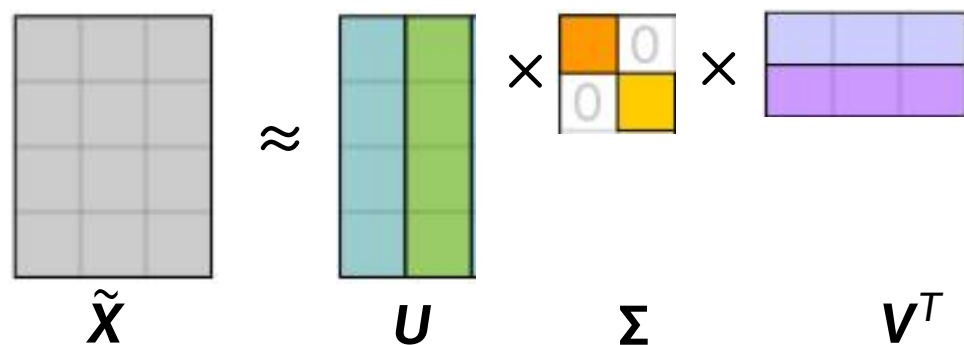
- 问题:

给定  $\tilde{X}$  的 SVD 分解如下所示,  $\tilde{x}^{(n)}$  的主方向和系数  $a_i$ 's 是什么?



The diagram illustrates the SVD decomposition of a 4x4 matrix  $\tilde{X}$  (gray grid) into three components: a 4x3 matrix  $U$  (teal, green, and blue vertical stripes), a 3x3 diagonal matrix  $\Sigma$  (orange, yellow, and white squares), and a 3x4 matrix  $V^T$  (purple and pink horizontal stripes). The equation is  $\tilde{X} = U \Sigma V^T$ .

如果只保留前两个方向, 系数  $a_i$ 's 是什么?



The diagram illustrates the truncated SVD decomposition of a 4x4 matrix  $\tilde{X}$  (gray grid) into three components: a 4x2 matrix  $U$  (teal and green vertical stripes), a 2x2 diagonal matrix  $\Sigma$  (orange and yellow squares), and a 2x4 matrix  $V^T$  (purple horizontal stripes). The equation is  $\tilde{X} \approx U \Sigma V^T$ .



# 线性降维PCA大纲

---

- 动机
- 视角 1：最小化重构误差
- 视角 2：最大化方差
- 视角 3：奇异值分解（SVD）
- PCA的其他应用


# 图像压缩

将一个  $372 \times 492$  的图像分割成多个  $12 \times 12$  的图像块


- 每个图像块被视为一个数据实例
- 在这些图像块上执行 PCA



## 重构误差 vs PCA 分量数



## 前 6 个 PCA 分量图示





使用前 60 个分量进行重构



使用前 16 个分量进行重构

# 图像去噪

噪声图像



去噪图像



由前 15 个主成分重构

# 课堂小结

---

- PCA的最小重建误差视角
- PCA的方差最大化视角
- PCA的矩阵分解（SVD）视角