



# 隐变量模型、EM算法和 变分自编码器

主讲人：林惊



# 无监督概率建模

---

- 在监督学习中，回归和分类都可以理解为是在学习条件概率分布

$$p(y|x; w)$$

- 在回归任务中，条件概率密度函数的形式通常假设为

$$p(y|x; w) = \mathcal{N}(y; w^T x, \sigma^2)$$

- 在分类任务中，条件概率密度函数的形式通常假设为

二分类:  $p(y|x) = (\sigma(xw))^y \cdot (1 - \sigma(xw))^{1-y}$

多分类:  $p(\mathbf{y}|x) = \prod_{k=1}^K [\text{softmax}_k(Wx)]^{y_k}$

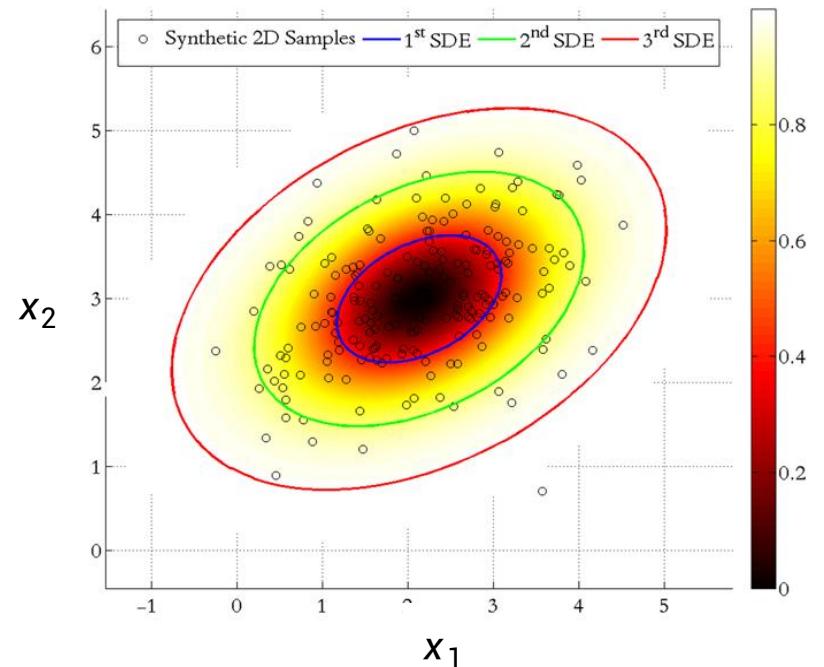
- 无监督学习也可以从学习概率分布的角度来理解。但它只关注输入数据  $\mathbf{x}$  的分布

$$p(\mathbf{x}; \mathbf{w})$$

- 建模  $\mathbf{x}$  要比标签  $y$  困难得多。一种朴素的方法是将  $p(\mathbf{x}; \mathbf{w})$  限制为高斯形式

$$p(\mathbf{x}; \mathbf{w}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

通过优化  $\boldsymbol{\mu}$  和  $\boldsymbol{\Sigma}$  来最优化地描述数据点  $\{\mathbf{x}^{(n)}\}_{n=1}^N$

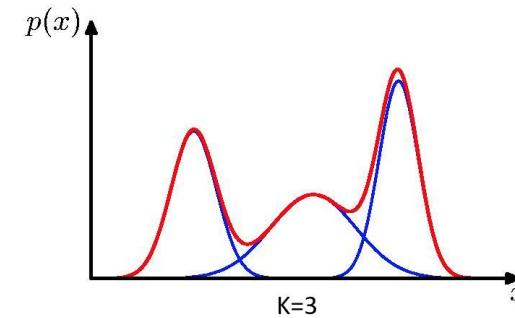


显然，该模型的表达能力非常有限

# 为什么需要隐变量？

- 理由1：通过组合简单模型构建更具表达能力的模型
  - 假设存在一个简单的类别分布  $p(z) = Cat(K, \pi)$  和一个高斯分布  $p(x) = \mathcal{N}(x|\mu, \sigma^2)$
  - 如果单独使用它们，只能对简单的统计关系进行建模
  - 但如果我们将它们组合成  $p(x, z) = p(x|z)p(z)$ ，所得到的边缘分布  $p(x)$  表达能力强得多

$$p(x) = \sum_z p(x|z)p(z) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \sigma_k^2)$$



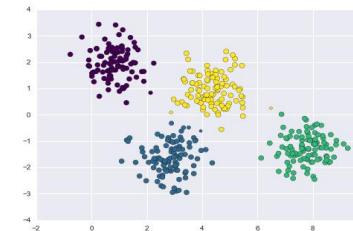
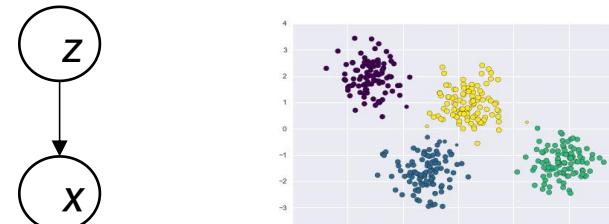
- 理论上，它能够表示任何复杂的分布

- 理由2：数据中隐藏的结构

- 1) 具有隐藏簇状结构的数据

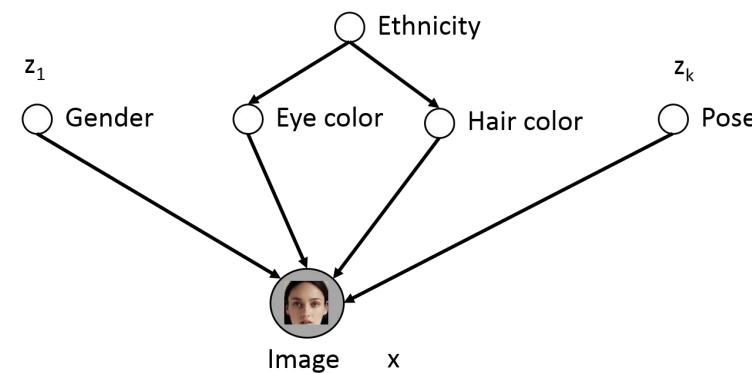
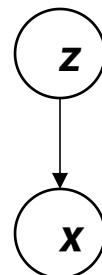
$$z_n \sim \text{Cat}(K, \pi)$$

$$x_n \sim \mathcal{N}(x | \mu_{z_n}, \Sigma_{z_n})$$



- 2) 面向文档的主题模型

- 3) 图像建模



- 在上面的例子中，隐变量  $z$  通常对应于高层级特征
- 如果考虑到这种隐藏结构，就可以获得更具可解释性的模型

# 隐变量模型的一般形式

---

- 隐变量模型 (LVMs) : 含有隐变量的概率模型

$$p(x, z)$$

- $x$  是我们感兴趣的随机变量
  - $z$  是隐变量 (Latent Variable)
- 有时可能存在多个隐变量  $z_1, z_2, \dots, z_K$

$$p(x, z_1, z_2, \dots, z_K)$$

- 关于我们感兴趣的变量  $x$  的概率模型是

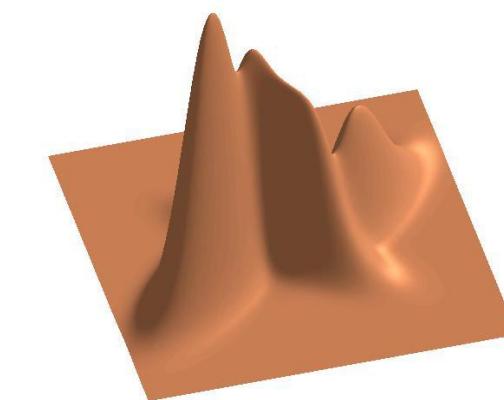
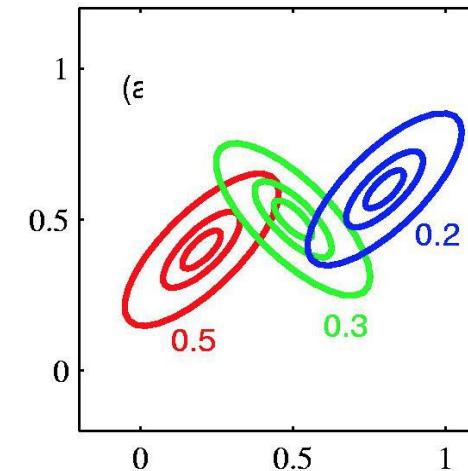
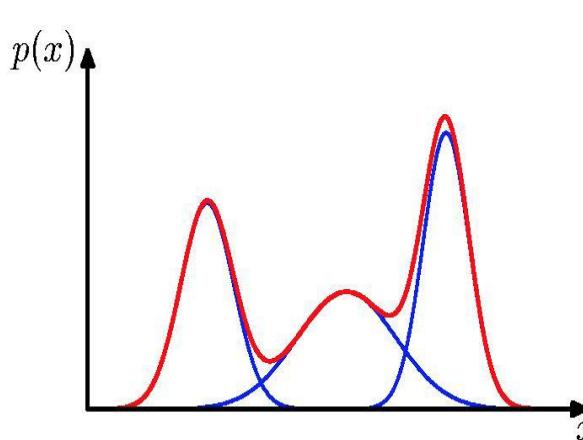
$$\begin{aligned} p(x) &= \int_z p(x, z) dz \quad \text{或} \quad p(x) = \int_{z_1 \dots z_K} p(x, z_1, \dots, z_K) dz_1 \dots dz_K \end{aligned}$$

# 高斯混合分布

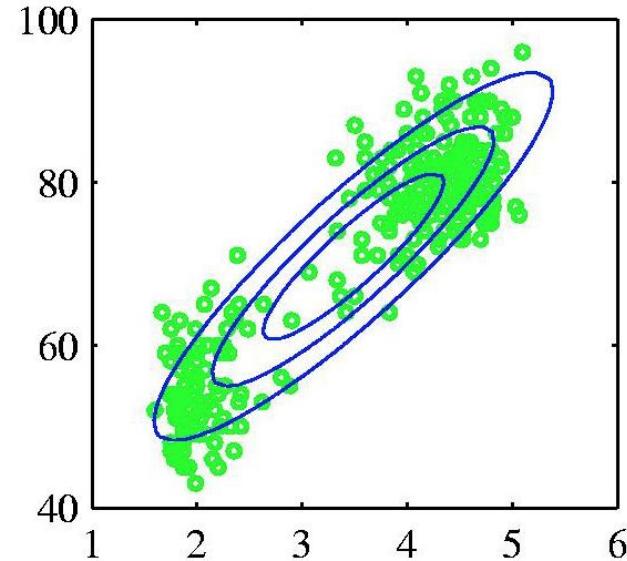
- 高斯混合分布的表达式

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

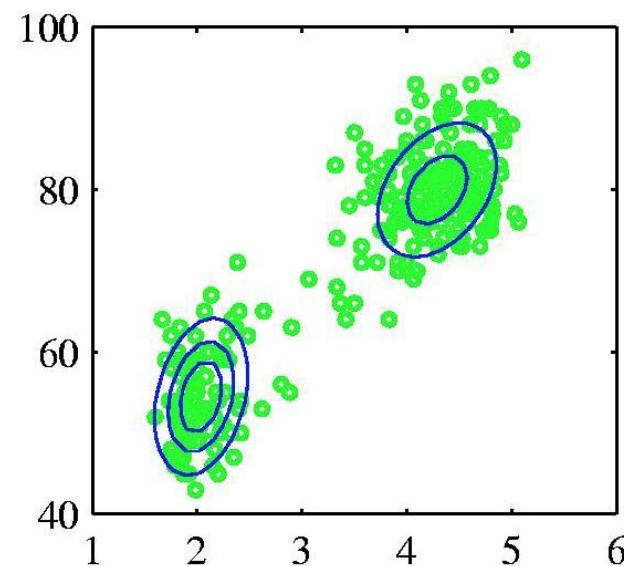
- $K$  表示高斯分布的数量
- $\pi_k$  是第  $k$  个分布的权重，满足  $\sum_{k=1}^K \pi_k = 1$
- $\boldsymbol{\mu}_k$  和  $\boldsymbol{\Sigma}_k$  分别是第  $k$  个高斯分布的均值向量和协方差矩阵



- 这些绿色的点很难用单个高斯分布建模



- 但如果用两个高斯分布的混合来建模，效果会好得多



# 将高斯混合分布表示为隐变量模型

- 对于一个隐变量模型  $p(\mathbf{x}, \mathbf{z})$ ，如果我们将其条件分布  $p(\mathbf{x}|\mathbf{z})$  和先验分布  $p(\mathbf{z})$  设为

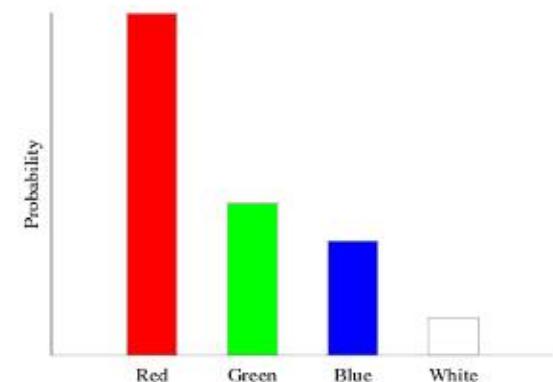
$$p(\mathbf{x}|\mathbf{z} = \mathbf{1}_k) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

$$p(\mathbf{z} = \mathbf{1}_k) = \pi_k$$

- $\mathbf{z}$  只能是一个 one-hot 向量，其中  $\mathbf{1}_k$  表示第  $k$  个元素为 1
- 由于  $p(\mathbf{z} = \mathbf{1}_k) = \pi_k$ ,  $p(\mathbf{z})$  实际上表示一个类别分布，即

$$p(\mathbf{z}) = Cat(\mathbf{z}; \boldsymbol{\pi})$$

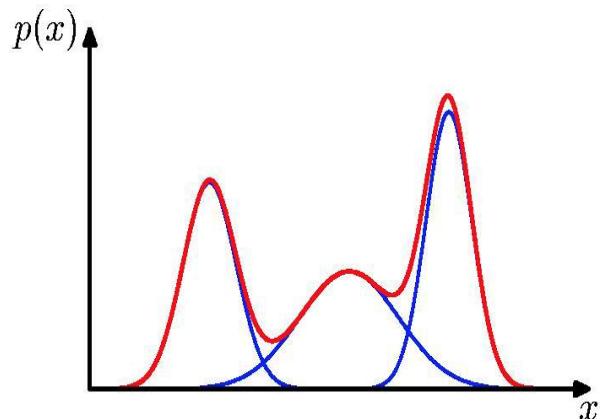
其中  $Cat(\mathbf{z} = \mathbf{1}_k; \boldsymbol{\pi}) = \pi_k$  且  $\boldsymbol{\pi} = [\pi_1, \pi_2, \dots, \pi_K]$



- 由于  $p(\mathbf{x}) = \sum_z p(\mathbf{x}, \mathbf{z})$ , 我们可以很容易得到

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k),$$

这正是高斯混合分布



- 因此，高斯混合分布也可以等价用隐变量模型来表示，其中  $p(\mathbf{x}|\mathbf{z} = \mathbf{1}_k) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ ,  $p(\mathbf{z} = \mathbf{1}_k) = \pi_k$

高斯混合分布的隐变量分布  $p(\mathbf{x}, \mathbf{z})$  可以写成如下形式

$$p(\mathbf{x}, \mathbf{z}) = \prod_{k=1}^K [\pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_k}$$

# 训练目标：最大化边缘概率分布

- 给定一组训练数据  $\{\mathbf{x}^{(n)}\}_{n=1}^N$ ， 目标是学习分布的参数

$$\{\pi_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}_{k=1}^K \triangleq \boldsymbol{\theta}$$

- 假设数据点  $\mathbf{x}^{(n)}$  是独立同分布的，因此我们可以将联合分布写为

$$p(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}) = \underbrace{\prod_{n=1}^N \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}^{(n)}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}_{p(\mathbf{x}^{(n)})}$$

未使用隐变量形式

- 对于概率模型，训练目标是**最大化对数似然函数**，即

$$\log p(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}) = \sum_{n=1}^N \log \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}^{(n)}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

# 针对问题的一般形式

- 给定联合分布

$$p(x, z; \theta),$$

其中  $x$  是观测变量， $z$  是隐变量，我们需要最大化关于  $\theta$  的对数似然，即

$$\theta = \arg \max_{\theta} \log p(x; \theta),$$

其中

$$p(x; \theta) = \sum_z p(x, z; \theta)$$

我们拥有的是 联合概率密度函数  $p(x, z; \theta)$ ，但需要优化的是边缘概率密度函数  
 $p(x; \theta)$

# 一般隐变量模型的训练

---

- 根据边缘分布与联合分布的关系，可知

$$p_{\theta}(x_n) = \int_{z_n} p_{\theta}(x_n, z_n) dz_n$$

训练目标就是最大化对数似然函数

$$\max_{\theta} \frac{1}{N} \sum_{n=1}^N \log p_{\theta}(x_n)$$

- 但是，由于积分的存在，很多时候，获得 $p_{\theta}(x_n)$ 的表达式是很困难的
- 因此，对于一般隐变量模型，计算对数似然的梯度  $\frac{d \log p_{\theta}(x)}{d \theta}$  是很困难的，使用梯度下降法来训练模型就变得非常具有挑战性

# 对数似然的重表示

- 对数似然可以重写为

$$\begin{aligned}\log p(\mathbf{x}; \boldsymbol{\theta}) &= \sum_{\mathbf{z}} q(\mathbf{z}) \log p(\mathbf{x}) && \forall \text{ 分布 } q(\mathbf{z}) \\ &= \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta}) q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}) q(\mathbf{z})} \\ &= \underbrace{\sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta})}{q(\mathbf{z})}}_{\mathcal{L}(q, \boldsymbol{\theta})} + \underbrace{\sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})}}_{KL(q||p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}))} \\ &= \mathcal{L}(q, \boldsymbol{\theta}) + KL(q||p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta})), \quad \text{for } \forall \boldsymbol{\theta}, q(\mathbf{z})\end{aligned}$$

注：KL 散度用于衡量两个分布  $q$  和  $p$  之间的距离，定义为

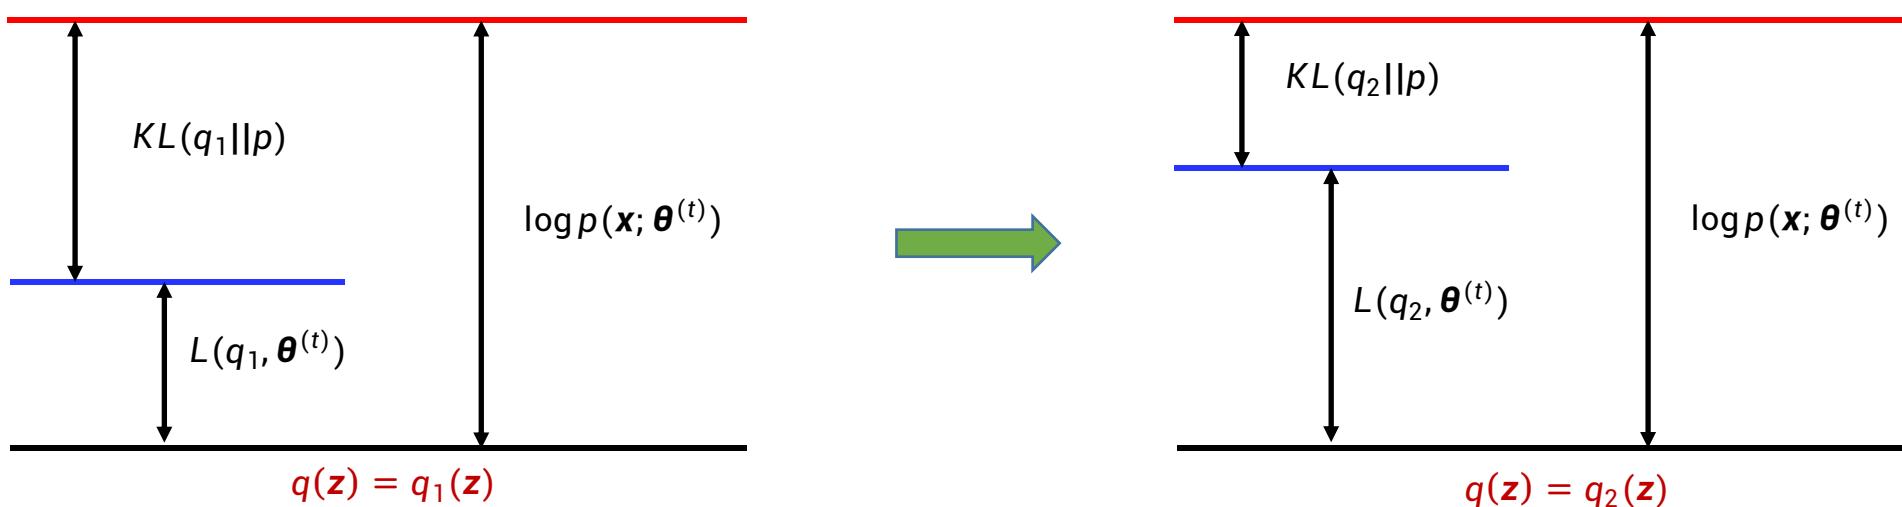
$$KL(q||p) \triangleq \int q(z) \log \frac{q(z)}{p(z)} dz \geq 0$$

- 因此，我们将第  $t$  次迭代的参数记为  $\theta^{(t)}$ ，可得

$$\log p(\mathbf{x}; \theta^{(t)}) = \mathbb{L}(q, \theta^{(t)}) + KL(q||p(\mathbf{z}|\mathbf{x}; \theta^{(t)}))$$

该等式对任何分布  $q(\mathbf{z})$  都成立

- 不同的  $q(\mathbf{z})$  会导致  $\log p(\mathbf{x}; \theta^{(t)})$  的不同分解



# EM 算法的理论依据

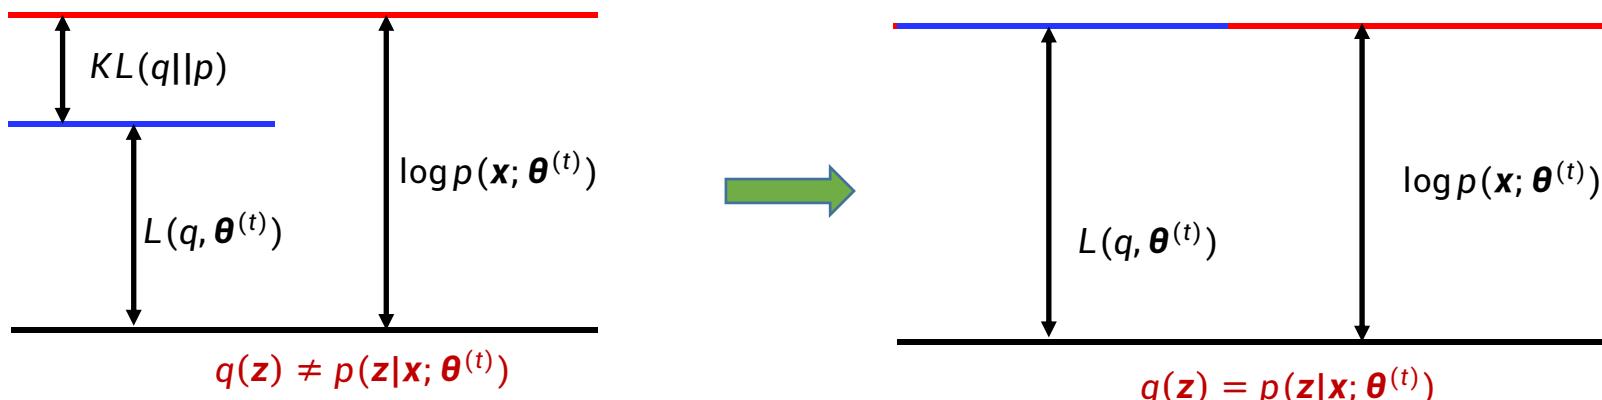
$$\log p(\mathbf{x}; \boldsymbol{\theta}^{(t)}) = \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta}^{(t)})}{q(\mathbf{z})} + \sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})}$$

- 如果我们设  $q(\mathbf{z}) = p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})$ , 那么可以得到

$$KL(q||p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})) = 0$$

因此, 我们有

$$\begin{aligned}\log p(\mathbf{x}; \boldsymbol{\theta}^{(t)}) &= L(p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}^{(t)}) \\ &= \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)}) \log \frac{p(\mathbf{x}, \mathbf{z}; \boldsymbol{\theta}^{(t)})}{p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})}\end{aligned}$$



$$\log p(\mathbf{x}; \boldsymbol{\theta}^{(t)}) = \mathbb{1}(p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}^{(t)}) = \sum_z p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)}) \log \frac{p(\mathbf{x}, z; \boldsymbol{\theta}^{(t)})}{p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)})}$$

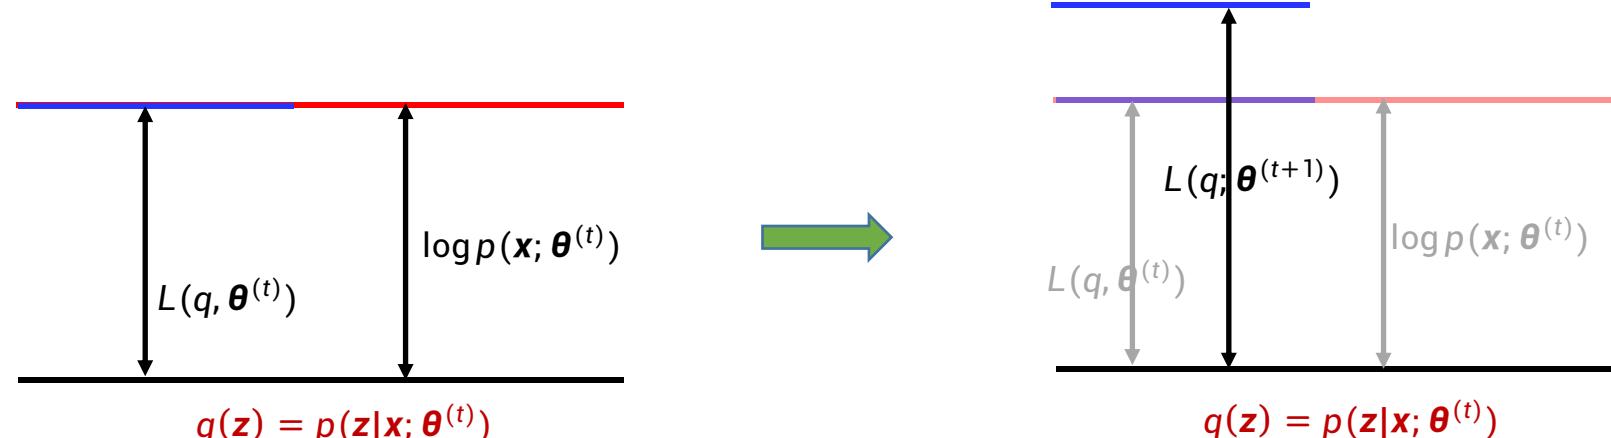
- 如果我们更新  $\boldsymbol{\theta}$  为

$$\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta}} \mathbb{1}(p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}),$$

那么我们必然得到如下关系

$$\mathbb{1}(p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}^{(t+1)}) \geq \underbrace{\mathbb{1}(p(z|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}^{(t)})}_{= \log p(\mathbf{x}; \boldsymbol{\theta}^{(t)})}$$

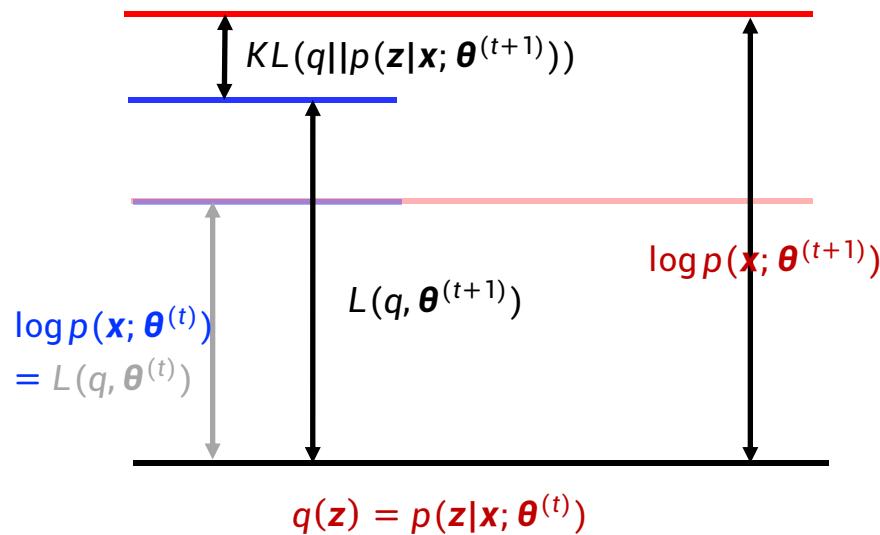
$$= \log p(\mathbf{x}; \boldsymbol{\theta}^{(t)})$$



- 通过设置  $q(\mathbf{z}) = p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)})$ , 我们得到

$$\log p(\mathbf{x}; \boldsymbol{\theta}^{(t+1)}) = \underbrace{\mathcal{L}(p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta}^{(t+1)})}_{\geq \log p(\mathbf{x}; \boldsymbol{\theta}^{(t)})} + \underbrace{KL(p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)}))||p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t+1)})}_{\geq 0}$$

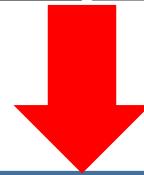
KL 散度始终为非负



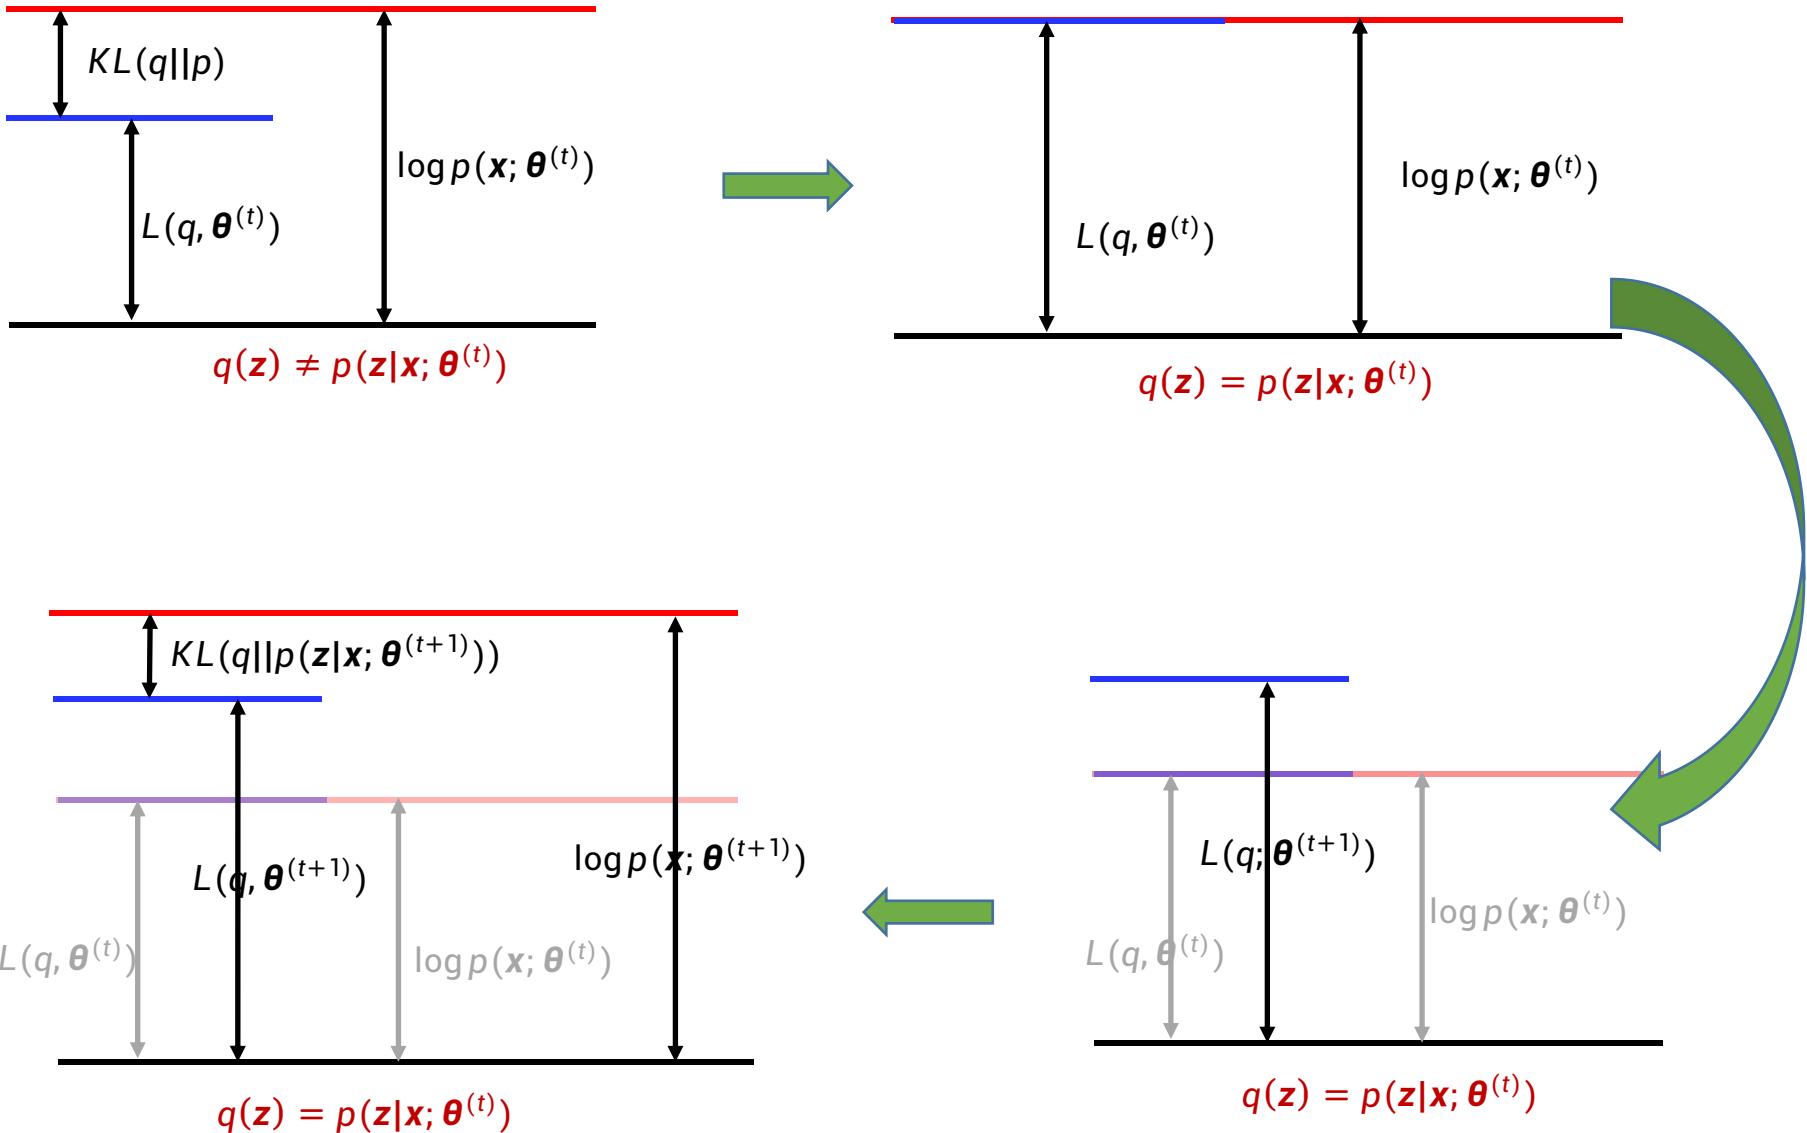
- 因此，我们可以看到

$$\log p(\mathbf{x}; \boldsymbol{\theta}^{(t+1)}) \geq \log p(\mathbf{x}; \boldsymbol{\theta}^{(t)})$$

KL 散度始终为非负



$\max_{\boldsymbol{\theta}} \text{L}(p(\mathbf{z}|\mathbf{x}; \boldsymbol{\theta}^{(t)}), \boldsymbol{\theta})$  能够保证每一步的似然函数值都会增加



# EM 算法

---

- 算法

*E 步:* 计算期望

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)}) = \mathbb{E}_{p(z|x; \boldsymbol{\theta}^{(t)})} [\log p(x, z; \boldsymbol{\theta})]$$

*M 步:* 更新参数 *EM* 算法可以保证每一步的似然函数值都会增加

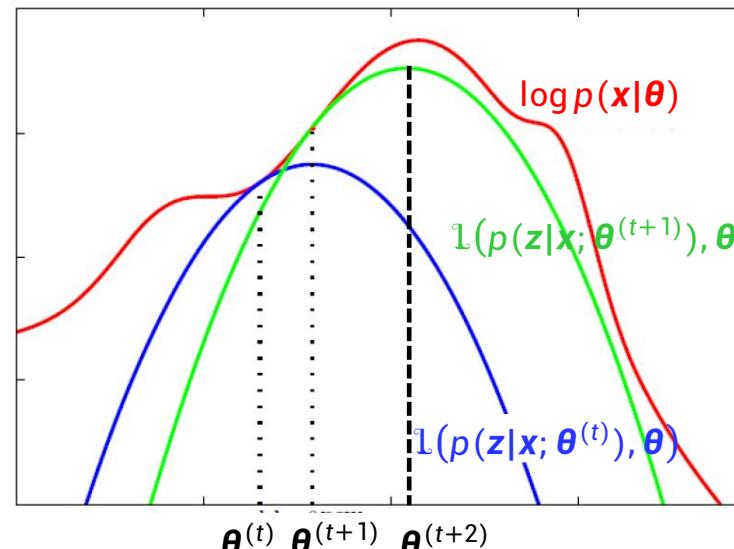
$$\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$$

- EM 算法的关键要素

- 1) 后验分布  $p(z|x; \boldsymbol{\theta}^{(t)})$
- 2) 联合分布对数  $\log p(x, z; \boldsymbol{\theta})$  关于后验概率的期望
- 3) 最大化

# 参数空间视角

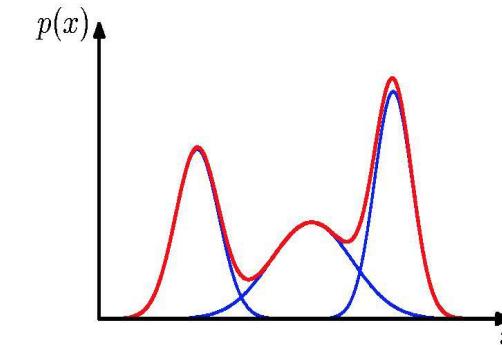
- 1) E 步 ( $t$ ): 给定模型参数  $\theta^{(t)}$  , 推导出  $\mathbb{L}(p(z|x; \theta^{(t)}), \theta)$  的表达式
- 2) M 步 ( $t$ ): 计算最优值  $\theta^{(t+1)} = \arg \max_{\theta} \mathbb{L}(p(z|x; \theta^{(t)}), \theta)$
- 3) E 步 ( $t + 1$ ): 给定模型参数  $\theta^{(t+1)}$  , 推导出  $\mathbb{L}(p(z|x; \theta^{(t+1)}), \theta)$  的表达式
- 4) 重复以上过程直至收敛



# 高斯混合模型回顾

- 对于一个高斯混合分布，即

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k),$$



它可以表示为联合分布的边缘分布

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x}|\mathbf{z})p(\mathbf{z})$$

$$= \prod_{k=1}^K [\pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)]^{z_k}$$

- $\mathbf{z} = [z_1, z_2, \dots, z_K]$  服从参数为  $\pi$  的类别分布

# EM 算法的两个步骤

- 这是一个隐变量模型，因此我们可以使用 EM 算法来优化它

注:  $\max_{\theta} \mathbb{L}(p(z|x; \theta^{(t)}), \theta)$  等价于  $\max_{\theta} Q(\theta; \theta^{(t)})$

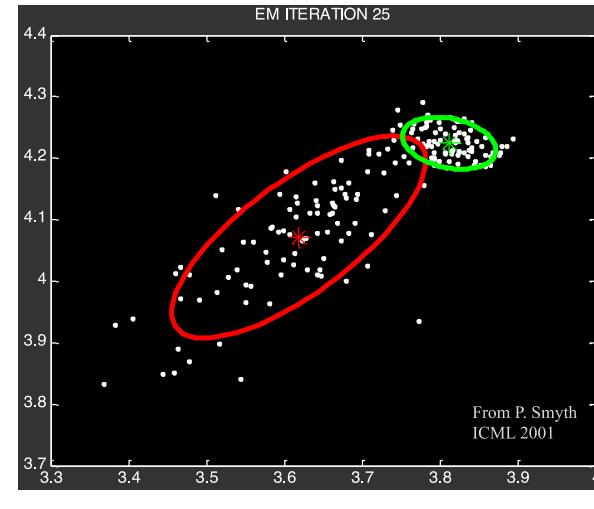
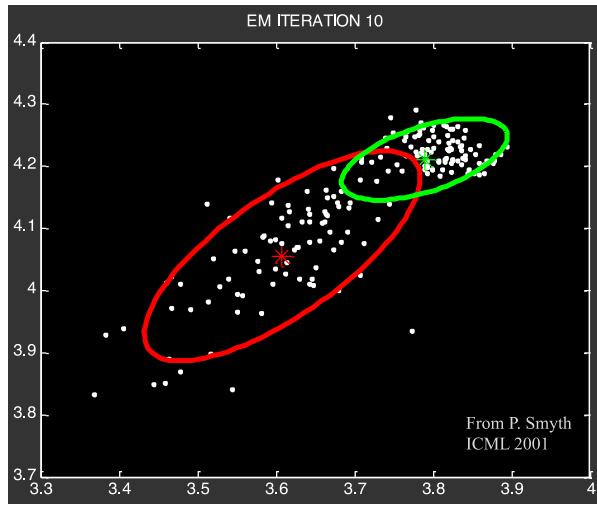
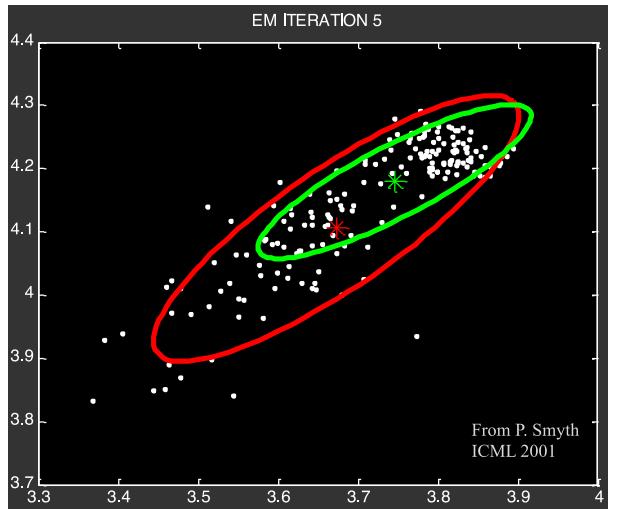
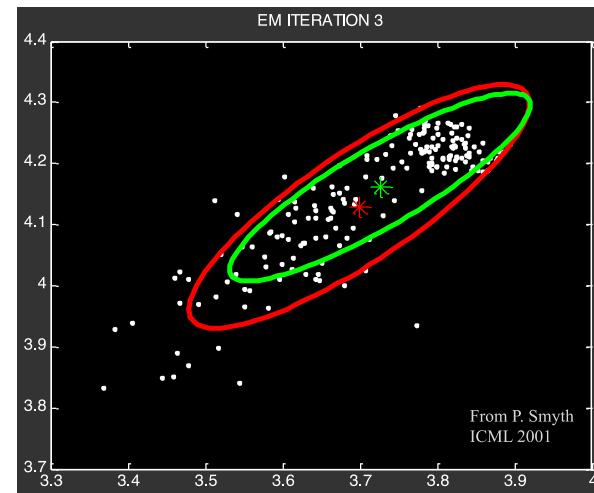
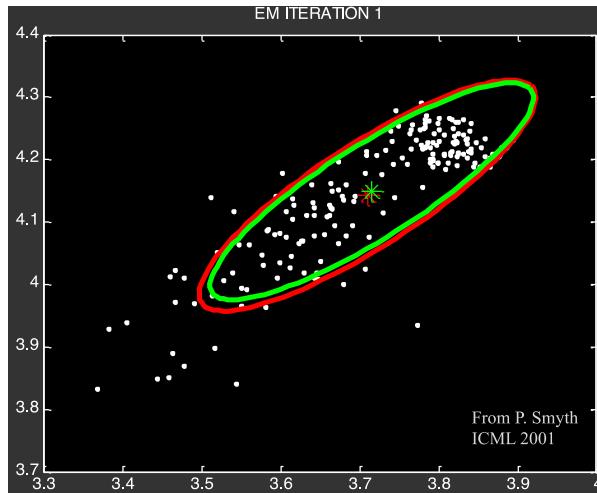
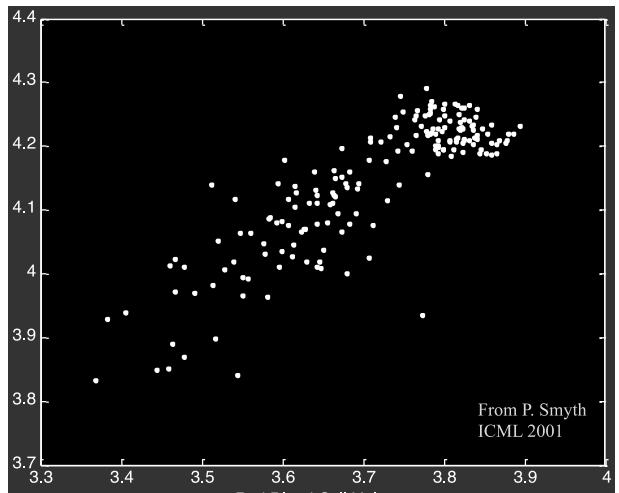
- 回顾: EM 算法的关键要素

➤ E 步: 计算关于后验概率  $p(z|x; \theta^{(t)})$  的期望

$$Q(\theta; \theta^{(t)}) = \frac{1}{N} \sum_{n=1}^N \mathbb{E}_{p(z^{(n)}|x^{(n)}; \theta^{(t)})} [\log p(x^{(n)}, z^{(n)}; \theta)]$$

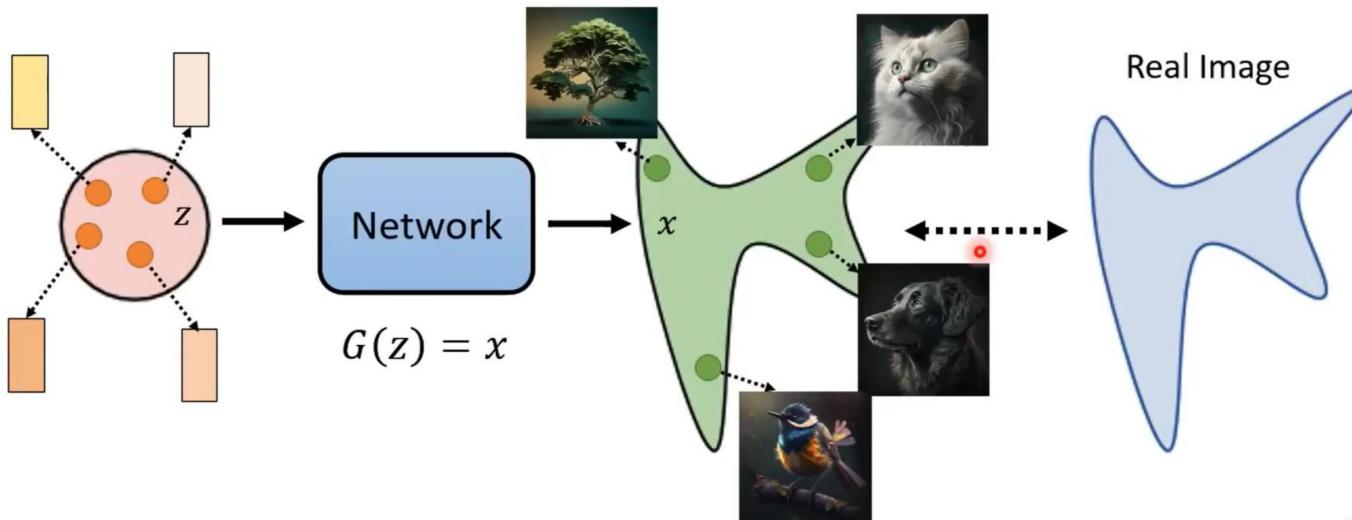
➤ M 步: 最大化

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta; \theta^{(t)})$$



# 从 EM 算法到变分自编码器

- 变分自编码器（Variational AutoEncoder, VAE）的直接数学目标就是：  
输入一个向量 $z$ , 经过模型得到 $G(z) = x$ , 希望这个得到的 $x$ 的分布 $p_\theta(x)$   
与实际已有数据的分布 $p_{data}(x)$ 尽可能接近



- 优化目标:

$$\theta^* = \arg \min_{\theta} KL(p_\theta(x), p_{data}(x)) = \arg \max_{\theta} \mathbb{E}_{x \sim p(data)} [p_\theta(x)]$$

# 从 EM 算法到变分自编码器

---

- 优化目标：

$$\theta^* = \arg \max_{\theta} \mathbb{E}_{x \sim p(\text{data})} [p_{\theta}(x)]$$

- EM算法最核心的地方在于，为隐变量 $z$ 引入了一个分布 $q(z)$ ：

$$\begin{aligned} L(\theta) &= \log p_{\theta}(x) = \int_z q(z) \log p_{\theta}(x|z) dz \\ &= \int_z q(z) \log \left( \frac{p(x, z|\theta)}{p(z|x, \theta)} \cdot \frac{q(z)}{q(z)} \right) dz \\ &= \int_z q(z) \log \frac{p(x|z, \theta) \cdot p(z)}{q(z)} dz \\ &= \underbrace{\mathbb{E}_{z \sim q(z)} [\log p_{\theta}(x|z)]}_{ELBO} + \underbrace{KL(q(z) \| p_{\theta}(z|x))}_{\text{KL散度}} \end{aligned}$$

# 从 EM 算法到变分自编码器

---

- 优化目标：

$$L(\theta) = \underbrace{\mathbb{E}_{z \sim q(z)} [\log p_\theta(x|z)] - KL(q(z)\|p(z))}_{ELBO} + \underbrace{KL(q(z)\|p_\theta(z|x))}$$

- EM算法的基本思路：先让KL散度取0，这样只剩一个ELBO项，最后让ELBO项最大。不断迭代直到收敛

*E步：*令 $q^{(t+1)}(z) = p_\theta(z|x)$ ，计算期望：

$$Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)}) = \mathbb{E}_{z \sim p_\theta(z|x)} [\log p_\theta(x|z)]$$

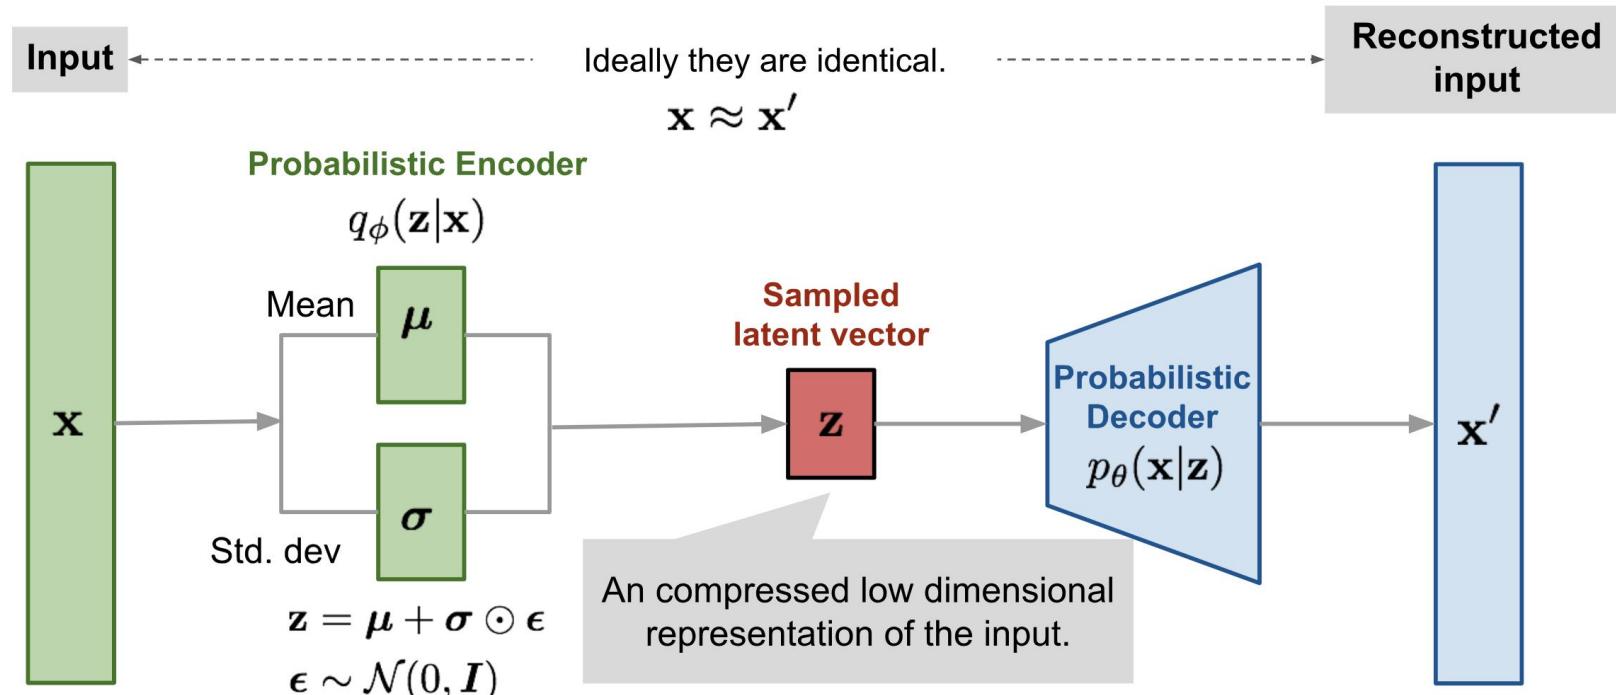
*M步：*更新参数：

$$\boldsymbol{\theta}^{(t+1)} = \arg \max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$$

# 变分自编码器

$$L(\theta) = \underbrace{\mathbb{E}_{z \sim q(z)} [\log p_\theta(x|z)] - KL(q(z)\|p(z))}_{ELBO} + \underbrace{KL(q(z)\|p_\theta(z|x))}$$

- 第一个改进：合并E-step和M-step，同时优化 $q(z), \theta$ 来达到一步到位 $\max_{q,\theta} ELBO$
- 第二个改进：对于 $q(z)$ 这个很难预测的分布，用深度学习模型 $q_\phi(z|x)$ 来进行控制



# 变分自编码器

- 变分自编码器的优化目标：

$$L(\theta) = \underbrace{\mathbb{E}_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{重建项}} + \underbrace{KL(q_\phi(z|x) \| p(z))}_{\text{正则项}}$$

